

MuQ-Transformer-P2OT による特徴確率経路と三項評価の小実験レポート

GSFTr-DIM 予備実験: 平均特徴・時間経路・自己構造の分離可能性

田中彬
立教大学理学部数学科

2026 年 5 月

Abstract

本レポートでは、楽曲を単一の静的ラベルではなく、確率単体上の時間的軌道として扱う GSFTr-DIM の小実験結果をまとめる。50 曲の MuQ 5 秒区間特徴を用い、Transformer encoder により文脈化した後、P2OT に基づく soft assignment を用いて特徴確率経路 $\Gamma_i = (\gamma_i^{(1)}, \dots, \gamma_i^{(T_i)})$ を生成した。その上で、平均状態分布距離 D_{mean} 、遷移差分付き DTW 距離 D_{path}^{Δ} 、自己距離行列 $\mathcal{A}_i$ に基づく entropic GW 構造距離 D_{struct} を計算し、三項評価 $D_{\eta, \alpha, \beta}$ に統合した。実験では、通常 DTW は時間順序シャッフルに対する感度が弱かった一方、遷移差分付き DTW ではシャッフル後距離が平均 0.132 増加し、時間的変化方向を組み込む有効性が示された。また、P2OT 版では D_{struct} と D_{mean} の Pearson 相関は 0.309、 D_{struct} と D_{path}^{Δ} の Pearson 相関は 0.248 であり、構造項が平均項・経路項とは異なる情報を持つことが確認された。さらに、2019 番楽曲は静的な特徴確率経路を示したが、5 秒単位のメル特徴変化も 2001 より低く、モデルの単純な collapse ではなく、音源側の 5 秒スケールの均質性を反映している可能性が示唆された。

1 目的

近年の楽曲はジャンル横断的であり、単一ジャンルラベルや曲全体の平均埋め込みだけでは、曲中の展開、反復、再訪、対比を十分に表現しにくい。本小実験の目的は、楽曲 i を時間順序付きの確率軌道

$$\Gamma_i = (\gamma_i^{(1)}, \dots, \gamma_i^{(T_i)}), \quad \gamma_i^{(t)} \in \Delta^{K-1} \quad (1)$$

として表し、平均的特徴、時間的展開、内部自己構造を分離して比較できるかを検証することである。

本レポートでは、従来の KMeans soft warm-up 版と P2OT fine-tuning 版を比較し、特に P2OT によって prototype 使用率の偏りが緩和されるか、また三項評価が意味のある近傍構造を生成するかを確認する。

2 手法

2.1 5 秒窓と MuQ 特徴

楽曲 x_i を 5 秒単位に分割し、区間数を

$$T_i = \left\lceil \frac{L_i}{5} \right\rceil \quad (2)$$

とする。各区間から MuQ layer 10 による 1024 次元特徴を抽出し、曲 i を

$$Z_i = (z_i^{(1)}, \dots, z_i^{(T_i)}) \in \mathbb{R}^{T_i \times 1024} \quad (3)$$

として扱う。5 秒窓を用いる理由は、フレーム単位の微細なゆらぎではなく、区間単位の音楽的状态や構造的変化を捉えるためである。この方針は研究計画書の手法定式化とも対応している [1]。

2.2 Transformer prototype model

入力特徴を内部次元 $d = 256$ へ射影し、位置埋め込みを加えた後、2 層の Transformer encoder に入力する。出力 $h_i^{(t)}$ に対し、 $K = 8$ 個の潜在状態 prototype への softmax を計算し、

$$\gamma_i^{(t)} = \text{softmax} \left(\frac{s(h_i^{(t)}, c_1), \dots, s(h_i^{(t)}, c_K)}{\tau} \right) \quad (4)$$

を得る。本実験では温度 $\tau = 0.5$ を用いた。Transformer により、隣接区間だけでなく離れた区間同士の関係も確率経路へ反映することを狙う。

2.3 P2OT fine-tuning

KMeans soft warm-up 後のモデルを初期値として、P2OT による pseudo-label fine-tuning を行った。ミニバッチ内の予測確率行列を $P \in \mathbb{R}^{N \times K}$ とし、実クラスタへの輸送量 Q を求める。実験では、仮想クラスタを加えた部分輸送を用い、総実質量 ρ を段階的に増加させた。概念的には、

$$\min_Q \langle Q, -\log P \rangle_F + \lambda \text{KL} \left(Q^\top \mathbf{1}_N, \frac{\rho}{K} \mathbf{1}_K \right) \quad (5)$$

を考え、曖昧なサンプルを仮想クラスタへ逃がしながら実クラスタ使用率を制御する。P2OT は不均衡クラスタリングのための Progressive Partial Optimal Transport として提案された手法である [3]。

2.4 三項評価

本実験では、楽曲間距離を以下の 3 項に分けた。第 1 に、平均状態分布

$$\bar{\gamma}_i = \frac{1}{T_i} \sum_{t=1}^{T_i} \gamma_i^{(t)} \quad (6)$$

Table 1: 実験条件

項目	設定
データ	既存の GSFTr-DIM.ipynb 小実験データを流用. 50 曲, track id 2001–2058 の一部.
区間長	5 秒窓, 末尾は残り区間として使用.
特微量	MuQ layer 10, 1024 次元区間特徴.
モデル	Transformer encoder, hidden dim 256, 2 layers, 4 heads, dropout 0.1, $K = 8$ prototypes.
学習	soft warm-up 後, P2OT fine-tuning 15 epochs, lr 10^{-4} .
P2OT	$\rho : 0.4 \rightarrow 0.9$ schedule, $\epsilon = 0.05$, $\lambda_{KL} = 1.0$, Sinkhorn 100 iterations.
距離	D_{mean} , D_{path}^{Δ} with $\lambda_{\Delta} = 0.5$, D_{struct} with entropic GW $\epsilon = 0.05$.
三項重み	$\eta = 0.34, \alpha = 0.33, \beta = 0.33$.

に対する平均距離

$$D_{\text{mean}}(i, j) = \frac{\sqrt{\text{JS}(\bar{\gamma}_i, \bar{\gamma}_j)}}{\sqrt{\log 2}}. \quad (7)$$

第 2 に, 状態そのものだけでなく状態変化方向を含む遷移差分付き DTW 距離

$$D_{\text{path}}^{\Delta}(i, j) = \text{DTW}(\Gamma_i, \Gamma_j; c_{\Delta}), \quad (8)$$

ただし局所コストは

$$c_{\Delta}(t, s) = (1 - \lambda_{\Delta}) \frac{\sqrt{\text{JS}(\gamma_i^{(t)}, \gamma_j^{(s)})}}{\sqrt{\log 2}} + \lambda_{\Delta} \frac{\|\Delta\gamma_i^{(t)} - \Delta\gamma_j^{(s)}\|_2}{2\sqrt{2}}, \quad (9)$$

であり, $\lambda_{\Delta} = 0.5$ とした. 第 3 に, 自己距離行列

$$A_i(t, s) = \sqrt{\text{JS}(\gamma_i^{(t)}, \gamma_i^{(s)})} \quad (10)$$

を作り, A_i と A_j の entropic GW 距離を D_{struct} とする. 自己距離行列は Music Structure Analysis における自己類似行列の考え方と対応する [4]. 最終的な三項評価は

$$D_{\eta, \alpha, \beta}(i, j) = \eta D_{\text{mean}}(i, j) + \alpha D_{\text{path}}^{\Delta}(i, j) + \beta D_{\text{struct}}(i, j) \quad (11)$$

であり, 実験では $\eta = 0.34, \alpha = 0.33, \beta = 0.33$ とした. D_{struct} はスケール差があるため, ランキングでは min-max 正規化した値を用いた.

3 結果

3.1 通常 DTW と遷移差分付き DTW

まず, 通常 DTW, 制約付き DTW, 遷移差分付き DTW の時間順序感度を検証した. 各系列の時刻順序をランダムにシャッフルし,

$$\Delta_{\text{shuffle}} = D_{\text{shuffle}} - D_{\text{original}} \quad (12)$$

を計算した. 通常 DTW では平均 0.0025, 制約付き DTW では -0.0059 とほぼゼロであったのに対し, 遷移差分付き DTW では平均 0.1323, 中央値 0.1245 であった. したがって, 状態そのものだけでなく $\Delta\gamma$ を局所コストに入れることで, 時間順序破壊に明確に反応することが確認された.




Fig. 1: 通常 DTW, 制約付き DTW, 遷移差分付き DTW のシャッフル感度. 遷移差分付き DTW のみ正方向に明確な増加を示した.

Table 2: track 2001 における soft warm-up 版と P2OT 版の比較

指標	soft	P2OT
entropy mean	1.427	1.528
prototype 4 usage	0.535	0.341
prototype 7 usage	0.059	0.189
$\mathcal{A}$ max	0.518	0.539
δ mean	0.091	0.162
δ max	0.518	0.535

3.2 P2OT による prototype 使用率の改善


2001 番楽曲において, soft warm-up 版では prototype 4 への平均使用率が 0.535 と高かった. P2OT 版では prototype 4 が 0.341 へ低下し, prototype 7 が 0.059 から 0.189 へ増加した. エントロピー平均も 1.427 から 1.528 へ増加し, 一様 collapse ではなく, 多様な潜在状態を利用する方向に変化した.

3.3 P2OT 版三項距離の分布と相関


P2OT 版で全ペア $\binom{50}{2} = 1225$ の距離を計算した. D_{mean} と D_{path}^{Δ} は Pearson 0.876, Spearman 0.777 と高い相関を持つが, D_{struct} と D_{mean} の Pearson 相関は 0.309, D_{struct} と D_{path}^{Δ} の Pearson 相関は 0.248 に留まった. これは, 構造項が平均状態分布や経路項とは異なる情報を持つことを示す.

3.4 soft 版と P2OT 版の近傍ランキング差

soft 版と P2OT 版の track 2001 に対する三項近傍を比較したところ, Top-5 の共通曲は 2021 の 1 曲のみであり, Jaccard 係数は 0.111 であった. 一方, Top-15 で



(a) P2OT 版 Γ_{2001}



(b) soft 版と P2OT 版のエントロピー比較

Fig. 2: track 2001 における P2OT 特徴確率経路と entropy の変化. P2OT により prototype 4 への過集中が緩和され, 補助的な潜在状態が利用されるようになった.

Table 3: P2OT 版三項距離の相関

組合せ	Pearson	Spearman
D_{mean} vs D_{path}^{Δ}	0.876	0.777
D_{mean} vs D_{struct}	0.309	0.315
D_{path}^{Δ} vs D_{struct}	0.248	0.296
$D_{\eta,\alpha,\beta}$ vs D_{mean}	0.801	0.748
$D_{\eta,\alpha,\beta}$ vs D_{path}^{Δ}	0.739	0.714
$D_{\eta,\alpha,\beta}$ vs D_{struct}	0.808	0.824

Table 4: soft 版と P2OT 版の Top-K overlap

K	overlap	Jaccard
5	1	0.111
10	5	0.333
15	10	0.500
20	13	0.481

Table 5: P2OT 版における track 2001 の三項近傍上位

neighbor	D_{mean}	D_{path}^{Δ}	D_{struct}	$D_{\eta,\alpha,\beta}$
2057	0.220	0.137	0.247	0.201
2029	0.111	0.151	0.363	0.207
2021	0.128	0.092	0.419	0.212
2023	0.230	0.114	0.307	0.217
2039	0.270	0.115	0.273	0.220




Fig. 3: P2OT 版における D_{mean} , D_{path}^{Δ} , D_{struct} , $D_{\eta,\alpha,\beta}$ の分布. 構造項は分布幅が広く, 三項評価へ強く寄与する.

は共通 10 曲, Jaccard 0.500 となった. これは, P2OT が候補集合を完全に破壊するのではなく, 上位近傍の優先順位を再評価していることを示す.

P2OT 版の track 2001 に対する三項近傍上位は, 2057, 2029, 2021, 2023, 2039 であった. 2057 は $D_{\text{mean}} = 0.220$, $D_{\text{path}}^{\Delta} = 0.137$, $D_{\text{struct}} = 0.247$, $D_{\eta,\alpha,\beta} = 0.201$ と三項が比較的低く, バランス型近傍として解釈できる.

3.5 最遠曲 2019 の診断

track 2001 から最も三項距離が大きい曲として, 2019 が抽出された. 距離内訳は $D_{\text{mean}} = 0.568$, $D_{\text{path}}^{\Delta} = 0.341$, $D_{\text{struct}} = 0.857$, $D_{\eta,\alpha,\beta} = 0.588$ であり, 特に構造項が大きい. 3D 経路では 2019 の軌道はほぼ一点に集中し, 自己距離行列もほぼゼロに近い.

2019 の詳細診断では, $T = 36$, entropy mean 1.4685, entropy std 0.0075, $\mathcal{A}$ mean 0.0084, $\mathcal{A}$ max 0.0639, δ mean 0.0065, γ の時間方向標準偏差平均 0.0023 であ

った. これは全曲中でも極めて小さく, 2019 は P2OT 表現上で「静的軌道型」の代表例である. ただし, soft 版でも $\mathcal{A}$ max 0.0541, δ mean 0.0083 と非常に小さく, P2OT によって突然 collapse したわけではない.

3.6 メルスペクトログラムによる仮説 A の検証

2019 が実際に音響的变化の少ない曲であるかを調べるため, 2001 と 2019 のメルスペクトログラムを比較した. フレーム単位のメルスペクトル変化平均は, 2001 が 30.39, 2019 が 42.27 であり, 2019 は短時間フレーム単位では細かな変動を持つ. しかし, 本研究の表現単位である 5 秒セグメントに平均化すると, 2001 の 5 秒メル変化平均は 41.38, 2019 は 29.98 となり, 2019 の方が低い. 最大変化量も 2001 が 236.72, 2019 が 121.56 であり, 5 秒スケールの大域的構造変化は 2019 の方が弱い.

4 考察

4.1 三項評価の役割分離

本実験では, D_{mean} と D_{path}^{Δ} は一定の相関を持つ一方, D_{struct} は比較的独立した情報を持つことが示された. これは, 楽曲の「どの状態をどれだけ使うか」と「どの

Table 6: track 2019 の静的軌道診断

指標	2019	2001
T	36	60
entropy mean	1.4685	1.5285
entropy std	0.0075	0.0837
usage max	0.5921	0.3408
γ time std mean	0.0023	0.0894
$\mathcal{A}$ mean	0.0084	0.3098
$\mathcal{A}$ max	0.0639	0.5391
δ mean	0.0065	0.1621
δ max	0.0624	0.5350

Table 7: メル特徴変化量の比較

指標	2001	2019
frame-level mean	30.39	42.27
frame-level std	8.86	13.97
frame-level max	333.11	226.39
duration [sec]	301.64	180.51
5-sec segments	61	37
5-sec mean	41.38	29.98
5-sec std	32.28	19.82
5-sec max	236.72	121.56

ように変化するか」と「曲内部の反復・再訪・対比構造」は同一ではないことを意味する。特に P2OT 版では prototype 使用率が改善し、soft 版よりも上位近傍ランキングが大きく再編成された。この結果は、P2OT が単にランキングを壊したのではなく、候補集合をある程度共有しつつ、構造的・経路的情報に基づいて優先順位を再評価したものと解釈できる。

4.2 2019 の意味

2019 は一見すると異常出力のように見えるが、soft 版でも P2OT 版でも静的であり、MuQ embedding の時間変動も小さい側にある。さらに、原音源のメルスペクトログラムでは、5 秒スケールの大域的变化が 2001 より弱かった。したがって、2019 はモデルの単純な失敗例というより、5 秒セグメント表現上で音響的に均質な曲として判定された事例と考えられる。一方、フレーム単位では 2019 も細かな変動を持つため、この結果は「音響変化が無い」ことではなく、「本研究の 5 秒窓・MuQ・P2OT 表現が捉える構造変化が少ない」ことを意味する。

4.3 限界

本実験は 50 曲の小規模予備実験であり、Harmonix Set や SALAMI などの構造アノテーション付きデータによる客観評価は未実施である。また、P2OT のハイパーパラメータ $\rho, \epsilon, \lambda_{KL}$, prototype 数 K , Transformer 層数, MuQ 層選択の影響も十分には検証していない。したがって、本結果は提案表現の可能性を示す初期的な証拠であり、今後は境界検出指標、自己構造比較、推薦近傍評価を組み合わせた検証が必要である。

5 結論

本小実験では、MuQ-Transformer-P2OT により確率単体上の特徴確率経路 Γ_i を生成し、平均項、遷移差分付き経路項、自己距離行列に基づく構造項を組み合わせた三項評価を実装した。通常 DTW はシャッフル検定で時間順序感度が弱かったが、遷移差分付き DTW では時間順序破壊に明確に反応した。P2OT 版では prototype 使用率が改善し、構造項が平均項・経路項とは異なる情報を持つことが確認された。さらに、2019 の静的軌道はモデルの単純な collapse ではなく、5 秒スケールの音響的均質性と整合している可能性が高い。以上より、本手法は楽曲を「平均的特徴」「時間的展開」「内部構造」の三側面から比較する枠組みとして有望である。

謝辞

本レポートは、Google Colab 上の GSFTTr-DIM 小実験ログ、P2OT 版特徴確率経路、自己距離行列、メルスペクトログラム診断結果に基づき作成した。

References

- [1] 田中彬, “GSFTTr-DIM research plan / Method approach, cost-aware version,” 2026.
- [2] H. Zhu et al., “MuQ: Self-Supervised Music Representation Learning with Mel Residual Vector Quantization,” arXiv:2501.01108, 2025.
- [3] C. Zhang, H. Ren, and X. He, “P2OT: Progressive Partial Optimal Transport for Deep Imbalanced Clustering,” ICLR, 2024.
- [4] O. Nieto et al., “Audio-Based Music Structure Analysis: Current Trends, Open Challenges, and Applications,” Transactions of the International Society for Music Information Retrieval, vol. 3, no. 1, pp. 246–263, 2020.
- [5] A. Vaswani et al., “Attention Is All You Need,” NeurIPS, 2017.
- [6] M. Cuturi, “Sinkhorn Distances: Lightspeed Computation of Optimal Transport,” NeurIPS, 2013.
- [7] G. Peyré, M. Cuturi, and J. Solomon, “Gromov-Wasserstein Averaging of Kernel and Distance Matrices,” ICML, 2016.

P2OT K8: 3D feature probability trajectories and self-distance matrices




Fig. 4: P2OT 版における track 2001 と近傍曲の 3D 特徴確率経路および自己距離行列. 左列は共通 PCA 空間における Γ_i の 3D 軌道, 右列は $\mathcal{A}_i$ である. 近傍曲でも, 平均・経路・構造の寄与が異なることが視覚的に確認できる.

P2OT K8: Self-distance matrices for top neighbors




Fig. 5: P2OT 版三項近傍上位の自己距離行列. 暗いブロック, 明るい縦横帯, セクショナル的対比が曲ごとに異なり, D_{struct} が平均・経路とは別の構造情報を持つことを示す.

P2OT K8: target 2001 vs farthest attribute track 2019




Fig. 6: track 2001 と最遠曲 2019 の比較. 2019 は Γ_i がほぼ一定で, A_i も低値で一様である.




Fig. 7: 2019 と 2001 の詳細診断. 2019 は entropy そのものが低いというより, entropy と γ が時間方向にほぼ変化しない点の特徴である.




Fig. 8: 2019 における soft 版と P2OT 版の比較. soft 版の時点で Γ_i と A_i はほぼ静的であり, P2OT だけが原因ではない.




Fig. 9: 2001 と 2019 のメルスペクトログラム. 2019 はフレーム単位の細かな縦線の変動を持つが、大域的なセクション変化は 2001 より弱い.




Fig. 10: 短時間フレーム単位では 2019 も細かな変動を持つが、5 秒単位では 2001 より変化量が低い. これは P2OT 特徴確率経路が 2019 を静的に表現したことと整合する.