

小実験レポート 2

Transformer-P²OT による解像度可変な楽曲構造境界検出Harmonix 912 曲を用いた ε sweep と境界スコア設計の検証

田中彬（研究メモ） 2026 年 5 月 30 日

Keywords: Music Structure Analysis, P²OT, Optimal Transport, Probability Simplex, HR3F, Boundary Detection

1 目的

本実験の目的は、Transformer と P²OT によって得られる確率単体上の特徴確率経路 Γ_i が、楽曲構造境界の検出に有効かを検証することである。特に本日の実験では、P²OT の ε を単なる最適化パラメータではなく、楽曲構造分析の解像度制御パラメータとして扱う。すなわち、小さい ε では細粒度な局所変化を強く捉え、大きい ε では局所的なピークを抑えて大局的境界へズームアウトする、という仮説を検証した。

2 データセットと評価条件

評価には Harmonix 912 曲を用いた。3 秒窓単位の mel-spectrogram 表現を入力とし、Transformer による時系列文脈化の後、 $K = 16$ の確率単体上の系列へ写像した。予測境界は、Harmonix の正解境界に対して ± 3 秒の許容幅で評価した。表1に実験条件を示す。

表1: 実験条件

項目	設定
Dataset	Harmonix
tracks	912
segment	3.0 sec
K	16
boundary tolerance	± 3.0 sec
main metric	HR3F macro / micro

3 提案手法

3.1 特徴確率経路

各楽曲 i について、Transformer と P²OT により時系列確率経路

$$\Gamma_i = \{\gamma_i^{(1)}, \gamma_i^{(2)}, \dots, \gamma_i^{(T_i)}\}, \quad \gamma_i^{(t)} \in \Delta^{K-1} \quad (1)$$

を得る。ここで $K = 16$ であり、各 $\gamma_i^{(t)}$ は楽曲内の時刻 t における構造状態の確率表現である。P²OT は、

割当の不均衡性を制御しながら、入力確率 P を構造化された割当 Q へ写像する。本実験では、P²OT の ε を変化させることで、割当の硬さと境界検出性能の関係を調べた。

3.2 $\sqrt{JS}$ による隣接変化量

確率単体上の距離として Jensen-Shannon 距離を用いる。

$$D_{JS}(p, q) = \frac{1}{2}D_{KL}(p\|m) + \frac{1}{2}D_{KL}(q\|m), \quad m = \frac{p+q}{2}, \quad (2)$$
$$d_{\sqrt{JS}}(p, q) = \sqrt{D_{JS}(p, q)}. \quad (3)$$

隣接変化量は次で定義する。

$$\delta_{\text{adj}}(t) = d_{\sqrt{JS}}(\gamma^{(t)}, \gamma^{(t-1)}). \quad (4)$$

これは、直前状態から現在状態への瞬間的な構造変化を測るスコアである。

3.3 周辺変化量と混合境界スコア

隣接差分のみでは、滑らかなセクション遷移や前後文脈を十分に捉えられない可能性がある。そこで、境界候補時刻 t の前後 ℓ 区間の平均状態を比較する周辺変化量を定義した。

$$\delta_{\text{periph}}^{(\ell)}(t) = d_{\sqrt{JS}}\left(\frac{1}{\ell} \sum_{r=t-\ell}^{t-1} \gamma^{(r)}, \frac{1}{\ell} \sum_{r=t}^{t+\ell-1} \gamma^{(r)}\right). \quad (5)$$

さらに、隣接変化量と周辺変化量を min-max 正規化したうえで混合する。

$$s(t) = \lambda \tilde{\delta}_{\text{adj}}(t) + (1 - \lambda) \tilde{\delta}_{\text{periph}}^{(\ell)}(t). \quad (6)$$

ここで λ は隣接差分の寄与率である。

4 ε sweep の結果

まず、P²OT の ε を変化させ、確率経路の硬さと境界検出性能の関係を調べた。表2と図1に結果を示す。

$\varepsilon = 3.0$ 付近で HR3F_{macro} は最大となり、 $\varepsilon = 3.5$ および 5.0 では低下した。したがって、 $\varepsilon = 3.0$ 付近が、



(a) ϵ と境界検出性能(b) ϵ と entropy / delta std

図1: P²OT の ϵ sweep. ϵ を上げると entropy は増加し, delta std は低下する. これは局所的变化が抑制され, 大局構造へズームアウトしていることを示唆する.

表2: P²OT ϵ sweep の結果

epsilon	HR3F macro	HR3F micro	Macro-F1	entropy	delta std
0.800000	0.381694	0.392421	0.139211	0.723417	0.225605
1.000000	0.384328	0.394932	0.139387	0.839269	0.203941
1.200000	0.386341	0.397215	0.139514	0.937262	0.186537
1.500000	0.389950	0.401210	0.139655	1.057240	0.165605
2.000000	0.392764	0.403036	0.140118	1.205465	0.139318
3.000000	0.393213	0.403721	0.140034	1.388709	0.104471
3.500000	0.391627	0.402465	0.139172	1.447393	0.092304
5.000000	0.388719	0.399384	0.138850	1.555264	0.067430

局所変化を抑えつつ大局的境界を残す最適なズームアウト点であると考えられる.

5 境界スコア設計の結果

次に, P²OT $\epsilon = 3.0$ を固定し, 境界スコアのみを変更した. 隣接差分型, 周辺比較型, 混合型を比較したところ, 最良設定は

$$\ell = 2, \quad \lambda = 0.25, \quad \text{min_gap} = 12.0 \text{ sec} \quad (7)$$

であった. これは, 3 秒窓において境界前後それぞれ約 6 秒の平均状態を比較しつつ, 25% だけ隣接差分を混合する設定である.

最良設定では, $\text{HR3F}_{\text{macro}} = 0.411045$, $\text{HR3F}_{\text{micro}} = 0.422732$ を達成した. これは, Transformer teacher soft 3s の $\text{HR3F}_{\text{macro}} = 0.384328$, および P²OT $\epsilon = 3.0$ の隣接差分型 $\text{HR3F}_{\text{macro}} = 0.393213$ を上回る.


6 可視化分析

図3に, P²OT $\epsilon = 3.0$ の式 (5) 隣接差分による境界検出例と HR3F 分布を示す. 隣接差分は急峻な局所変化を捉える一方で, 滑らかなセクション遷移に対しては正解境界からずれる場合がある. このため, 本実験では前後文脈を含む周辺変化量を導入し, 混合スコアとして利用した.


7 考察

7.1 P²OT は解像度可変な構造レンズである

本実験により, P²OT の ϵ は楽曲構造分析における解像度制御パラメータとして機能することが確認された. 小さい ϵ では割当が hard になり, 細粒度の局所変化を拾いやすい. 一方, 大きい ϵ では割当が柔らかくなり, 局所的ピークが抑制され, 大局的構造へズームアウトした分析が可能となる. ただし, $\epsilon = 5.0$ のように大きすぎる場合は, 境界候補のピークまで平滑化され, 性能が低下する.



(a) 主要手法比較



(b) 境界スコア full sweep 上位

図2: P²OT $\varepsilon = 3.0$ と混合境界スコアにより, Transformer soft 系列を上回る性能を得た.

表3: 主要手法の比較

method	HR3F macro	HR3F micro	Macro-F1
Existing mel gamma K16	0.373982	0.383105	0.141252
Transformer teacher soft 3s	0.384328	0.394932	0.139387
Transformer P2OT eps=0.8	0.381694	0.392421	0.139211
P2OT eps=3.0 adjacent	0.393213	0.403721	0.140034
P2OT eps=3.0 mixed best	0.411045	0.422732	—

表4: P²OT $\varepsilon = 3.0$ 固定での境界スコア full sweep 上位 10 件

setting	HR3F macro	HR3F micro
mix ell2 lambda0.25 gap12	0.411045	0.422732
mix ell2 lambda0.30 gap7.5	0.409134	0.420043
mix ell2 lambda0.30 gap9	0.409134	0.420043
mix ell2 lambda0.25 gap9	0.409025	0.419473
mix ell2 lambda0.25 gap7.5	0.409025	0.419473
mix ell4 lambda0.50 gap12	0.408984	0.419807
mix ell2 lambda0.20 gap7.5	0.408683	0.419587
mix ell2 lambda0.20 gap9	0.408683	0.419587
mix ell3 lambda0.25 gap12	0.407438	0.419150
mix ell2 lambda0.40 gap7.5	0.406979	0.418103

7.2 境界検出には前後文脈が重要である

式 (5) の隣接差分は, 瞬間的な構造変化を捉えるには有効であるが, 楽曲構造境界は必ずしも 1 ステップの急変として現れるとは限らない. 本実験で最良となった $\ell = 2$ は, 境界前後それぞれ約 6 秒の平均状態を比較するものであり, 楽曲構造境界が前後文脈の状態差として現れることを示している.

7.3 min_gap=12 秒の意味

最良設定では, NMS の最小間隔として 12 秒が選ばれた. これは, P²OT $\varepsilon = 3.0$ による表現のズームアウトと, min_gap によるピーク選択のズームアウトが

組み合わせり, 細かすぎる候補を抑えて大局的なセクション境界を残したためと考えられる.


8 結論

本日の小実験により, 以下の知見が得られた.


1. P²OT の ε は, 楽曲構造分析における解像度制御パラメータとして機能する.
2. $\varepsilon = 3.0$ 付近で, 局所変化を抑えつつ大局境界を残すズームアウトが実現された.
3. RoPETransformer や Conformer への置換は, 現

表5: 最良設定の詳細

score	ell	lambda	min gap	HR3F macro	HR3F micro	precision	recall	TP	FP	FN
mix	2	0.250000	12.000000	0.411045	0.422732	0.423482	0.421984	3697	5033	5064



(a) 0926_sweetthing における隣接差分型境界検出の例



(b) 式 (5) 隣接差分型の HR3F 分布

図3: 隣接差分型境界スコアの例. 急峻なピークは検出できるが, 滑らかな遷移では前後文脈を含むスコア設計が必要となる.

時点では通常 Transformer を上回らなかった.

4. P²OT $\varepsilon = 3.0$ の確率経路に対し, 隣接差分と周辺変化量を混合した境界スコアを用いることで, $\text{HR3F}_{\text{macro}} = 0.411045$ を達成した.
5. 最良の境界スコアは, 前後 $\ell = 2$ 区間の周辺比較を主成分とし, 隣接差分を 25% 混合する構成であった.

最終的な主手法は, 次のように整理できる.

$$\text{Mel} \rightarrow \text{Transformer} \rightarrow P^2\text{OT}_{\varepsilon=3.0} \rightarrow \Gamma_i \rightarrow s(t). \quad (8)$$

ただし,

$$s(t) = 0.25 \tilde{\delta}_{\text{adj}}(t) + 0.75 \tilde{\delta}_{\text{periph}}^{(\ell=2)}(t) \quad (9)$$

であり, NMS の最小間隔は 12 秒とする.

今後の課題

今後は, 成功例・失敗例の可視化, GT 境界周辺と非境界周辺の mixed score 分離度の検証, 他データセットへの汎化性確認, ならびに ℓ , λ , min_gap の過学習可能性の検証を行う必要がある. また, 境界検出だけでなく, 自己距離行列や 3D 確率経路可視化により, P²OT の解像度制御性を多面的に確認することが重要である.