

実験レポート 3 : P²OT 構造遷移帯検出における Adaptive Interval と Top-k Budget 制御

今日の全実験ログに基づく Band-HR3F 改善実験の整理

田中彬
May 31, 2026

Abstract

本レポートは、P²OT に基づく楽曲構造遷移帯検出において、境界を一点ではなく局所帯的なグラデーション変化として扱うための評価・推定手順を整理したものである。今日の実験では、P²OT epsilon sweep、validation/test 分離、fold0 失敗分析、Dual-anchor/Band-HR3F、random band baseline、 F_β による選択、K=32 追加検証、score-side grid、Pareto frontier、B+C+E hard filtering、E-only entropy interval、曖昧さ・長さ・変動量に基づく adaptive interval、Top-k budget correction、そして HR3F=0.70 目標探索までを実施した。最良 fixed-grid では adaptive [12, 17] 探索により $HR3F_{macro} = 0.694491$ 、validation-selected では $HR3F_{macro} = 0.693450$ に到達した。0.70 到達に対する主なボトルネックは Recall ではなく Precision であり、今後は過検出を軽く抑える global Top-k scaling が有力である。

Keywords: Music Structure Analysis, P²OT, Band-HR3F, adaptive interval, structure transition band, precision-recall trade-off

1 背景と目的

楽曲のパート変化は、制作者視点では瞬間的な点変化だけではなく、数秒幅をもつ局所帯的なグラデーション変化として現れることが多い。本実験では、この観点から、予測境界点そのものではなく、予測境界帯 $B(p)$ が正解境界を覆うかどうかを評価する Band-HR3F を用いた。

参考とした MuQ 論文では、Mel-RVQ を用いた自己教師あり音楽表現学習を行い、Harmonix Set 上の Music Structure Analysis も下流評価の一つとして扱っている。本レポートのレイアウトは、同論文の二段組、booktabs 型表、図表中心の構成を参考にした。ただし、本レポートの対象は MuQ の再現ではなく、MuQ/P²OT 系表現を用いた構造遷移帯検出の評価改善である。

本日の到達点

- adaptive [12, 17] HR3F 探索で fixed-grid $HR3F_{macro} = 0.694491$ 。
- validation-selected でも $HR3F_{macro} = 0.693450$ まで到達。
- 主因は Recall 不足ではなく Precision 不足。平均予測数 13.821 に対し平均正解境界数 9.606 で、FP 過多が残る。
- 次の改善は Recall をさらに上げるのではなく、軽い FP 削減で Precision を 0.597 以上に上げる。

2 実際の演算定義

2.1 Score mix

境界候補スコアは、隣接変化スコア $s_{adj}(t)$ と周辺比較スコア $s_{periph}(t)$ の混合として定義した。

$$s(t) = (1 - \lambda)s_{periph}(t) + \lambda s_{adj}(t), \quad \lambda = 0.25. \quad (1)$$

本日の主設定では、スコア側の探索により $\lambda = 0.25$ を維持した。

2.2 Band-HR3F hit 判定

予測時刻を p 、正解境界を g とする。band-forward では予測帯を

$$B(p) = [p, p + \Delta] \quad (2)$$

とし、本実験では $\Delta = 6.0 \text{ sec}$, $\tau = 3.0 \text{ sec}$ とした。hit 判定は

$$d(g, B(p)) \leq \tau \quad (3)$$

であり、実質的には

$$g \in [p - \tau, p + \Delta + \tau] = [p - 3, p + 9] \quad (4)$$

に入る場合を正解扱いする。ただし予測帯そのものは $[p, p + 6]$ である。

2.3 F_β score

Precision と Recall のバランス調整には

$$F_\beta = \frac{(1 + \beta^2)\text{PrecisionRecall}}{\beta^2\text{Precision} + \text{Recall}} \quad (5)$$

を用いた。本日の探索では $\beta = 0.7$ を主に使用した。

2.4 曲ごとの曖昧さ・長さ・変動量

曲 i の score 系列 $s_i(t)$ から、曖昧さを正規化エントロピーとして定義した。

$$p_i(t) = \frac{s_i(t) - \min_t s_i(t) + \epsilon}{\sum_u (s_i(u) - \min_t s_i(t) + \epsilon)}, \quad (6)$$

$$A_i = -\frac{1}{\log T_i} \sum_{t=1}^{T_i} p_i(t) \log p_i(t). \quad (7)$$

変動量は score mix の時間方向 total variation とした。

$$V_i = \frac{1}{T_i - 1} \sum_{t=1}^{T_i - 1} |s_i(t + 1) - s_i(t)|. \quad (8)$$

実装では A_i, V_i, L_i を robust min-max 正規化した。

$$z(x) = \text{clip} \left(\frac{x - q_{0.05}}{q_{0.95} - q_{0.05}}, 0, 1 \right). \quad (9)$$

2.5 Adaptive interval

曲ごとの予測間隔 I_i は

$$I_i = \text{clip}(I_{\min} + (I_{\max} - I_{\min})(w_A A_i + w_L L_i - w_V V_i), I_{\min}, I_{\max}) \quad (10)$$

で決定する。曖昧な曲と長い曲では過検出を抑えるため interval を長くし、変動が激しい曲では構造変化を拾うため interval を短くする。

2.6 Top-k budget

曲長を D_i としたとき、基準予測数は

$$K_i^{\text{base}} = \text{round}\left(\frac{D_i}{I_i}\right) \quad (11)$$

である。Top-k correction では、短 interval 曲の過検出を抑えるため

$$K_i = \begin{cases} \text{round}(\alpha K_i^{\text{base}}), & I_i < \theta, \\ K_i^{\text{base}}, & \text{otherwise} \end{cases} \quad (12)$$

を試した。[14, 20] 実験では $\alpha = 0.90, 0.95$ 、HR3F=0.70 探索では $\theta \in \{12.5, 13.5, 14.5\}$ 、 $\alpha \in \{1.00, 0.98, 0.97, 0.95\}$ を探索した。

3 実験設定と使用ライブラリ

Table 1: 主な実験設定

項目	値
評価対象	Harmonix 912 tracks
分割	5-fold validation/test
Score mix	$\lambda = 0.25$
Band type	band-forward
Band width	$\Delta = 6.0$ sec
Tolerance	$\tau = 3.0$ sec
F_β	$\beta = 0.7$
主探索 interval	[12, 17] sec
比較 interval	[16, 18], [14, 20]
NMS	$\text{min_gap} \in \{10, 11, 12\}$ sec
Random baseline	同数・同幅のランダム境界帯

Table 2: 使用ライブラリと用途

ライブラリ	用途
NumPy	score 配列処理、正規化、距離計算、Top-k budget 計算
Pandas	CSV 読み込み、fold 別集計、per-track 結果表作成
Matplotlib	PR 平面、ヒートマップ、ヒストグラム、棒グラフの可視化
tqdm	912 曲およびグリッド探索の進行表示
PyTorch	Transformer/P ² OT 学習実験、CUDA 上のテンソル計算
pathlib/os/json/re	Google Drive パス処理、境界リスト復元、ログ保存
LaTeX/XeLaTeX	論文レイアウト PDF 作成、数式・表・図の整形

4 本日の実験の流れ

表3に、今日行った主要検証を一覧化する。重要なのは、前半で「点境界」から「構造遷移帯」へ評価仮説が

移り、後半で adaptive interval と Top-k budget の制御問題に収束した点である。

5 結果

5.1 主要設定の数値比較

5.2 Band-HR3F と random baseline

Dual-anchor/Band-HR3F の比較では、点境界 baseline を大きく上回り、構造遷移帯として評価することの有効性が示された。特に band-forward $\Delta = 6$ が 5-fold 全体で安定して選択された。また、同じ数・同じ幅の random band baseline と比較して、model は明確に高い HR3F と PR 領域に位置した。

5.3 Pareto frontier と empirical utopia

score-side grid では、expected interval が PR レジームを大きく支配し、mix_lambda はその中の微調整として働いた。PR 平面には明確な Pareto frontier が見られ、最大 Precision 点と最大 Recall 点を組み合わせる仮想点を empirical utopia として設定した。

5.4 B+C+E hard filtering の否定結果

relative threshold と peak prominence による hard filtering は、Precision を上げた一方で Recall を大きく落とした。最良付近で Precision = 0.668599 まで上がったが、Recall = 0.565202、HR3F = 0.597646 まで低下した。これは、構造遷移帯が鋭い点ピークではなく、台地状・グラデーション状に現れるという仮説と整合する。

5.5 E-only entropy と adaptive interval

E-only では、平均エントロピー最大の曲を interval=18、最小の曲を interval=16 として線形補間した。その結果、fixed18 より F_β がわずかに改善したが、星印への距離では fixed16 が優位であった。そこで、曖昧さ・長さ・変動量を組み合わせた式(10)を導入した。

5.6 Top-k budget correction

[14, 20] 系では、Precision を回復するために短 interval 曲の Top-k を抑制する補正を試した。0.90 補正は Recall 低下が目立ったが、0.95 補正では HR3F = 0.689303、Precision = 0.603940、Recall = 0.805216 となり、balanced setting としては有効であった。ただし最高 HR3F は adaptive [12, 17] 系が上回った。

5.7 HR3F=0.70 目標探索

adaptive [12, 17] をベースに、短 interval 補正、min_gap、選択基準を探索した。fixed-grid 最高は HR3F = 0.694491、Precision = 0.589523、Recall = 0.848227、validation-selected 最高は HR3F = 0.693450、Precision = 0.582451、Recall = 0.859315 であった。Recall は十分高いため、0.70 到達には Precision の軽微な改善が必要である。

6 考察

6.1 構造遷移帯としての妥当性

Band-HR3F が点境界 baseline を大きく上回ったことは、楽曲構造変化が点ではなく遷移帯として現れるという仮説を支持する。特に random band baseline を大きく上回ったため、単に評価幅を広げただけでは

Today's experiment timeline

1. P ² OT epsilon sweep	epsilon=2.0-3.0付近でHR3Fが上昇。epsilon=3.0を主候補化。
2. Step 1 valid/test	fold0でvalidation/testの差が大きく、以降の失敗分析対象にした。
3. Step 2 score separation	GT近傍のscore分布が高く、境界スコアが情報を持つことを確認。
4. fold0 failure analysis	separation_reversedやmixed_errorが主要失敗。時刻シフト補正だけでは解決しない。
5. Dual-anchor/Band-HR3F	band_forward, Delta=6が5-foldで安定。Point baselineから大きく改善。
6. random band baseline	modelはrandom distributionを大きく上回る。遷移帯評価の有効性を確認。
7. F-beta selection	beta=0.7がPrecision>=0.60付近でHR3Fを維持しやすい。
8. K=32 / rho sweep	K=32は明確な改善に至らず、K=16主設定を維持。rhoは主設定を大きく更新せず。
9. score-side grid	lambda=0.25, interval=18付近を主設定。interval=16は高Recall、22は高Precision。
10. Pareto/utopia	P*=0.647236, R*=0.825720をempirical utopiaとして距離を計測。

Figure 1: 本日の実験フロー前半。epsilon sweep、validation/test、score separation、fold0 failure analysis、Band-HR3F 化まで。

なく、P²OT score が正解境界近傍に情報を持っていると考えられる。

6.2 なぜ hard filtering は失敗したか

B+C+E hard filtering は Precision を上げるが、候補数を削りすぎたため Recall が急落した。構造遷移帯では鋭い局所ピークよりも、周辺数フレームにわたる高まりや台地状スコアが意味を持つ可能性が高い。したがって、今後は hard mask ではなく soft re-ranking や global Top-k scaling が有望である。

6.3 0.70 到達へのボトルネック

現在の最高点は Recall = 0.848227 と十分に高いが、Precision = 0.589523 である。F = 0.70 を達成するには、Recall を大きく上げるよりも、Precision を 0.597 前後へ上げることが重要である。平均予測数が平均正解数を約 4.2 個上回っているため、FP を 1 曲あたり 0.5-1 個程度削ることが次の改善目標になる。

7 結論

本日の実験により、P²OT に基づく構造遷移帯検出では、adaptive interval [12,17] が HR3F を最大化する有力な方向であることが分かった。最高値は fixed-grid で $HR3F_{macro} = 0.694491$ 、validation-selected で 0.693450 であり、HR3F=0.70 までの差は小さい。一方で、主な不足は Recall ではなく Precision である。今後は global Top-k scale $\in \{0.92, 0.94, 0.96, 0.98, 1.00\}$ などにより、Recall を 0.84 前後に保ちながら Precision を 0.597 以上へ引き上げることを目標とする。

Today's experiment timeline - continued

- | | |
|----------------------------------|--|
| 11. B+C+E hard filtering | Precisionは上がるがRecallが0.565まで落ち、構造遷移帯にはhard filteringが不適。 |
| 12. E-only entropy | fixed18よりFbetaが微改善。ただしfixed16の高Recallには届かず。 |
| 13. Amb+Len-Var interval [16,18] | HR3F=0.690562 fixed-grid。星印距離を改善。 |
| 14. interval [12,17] | validation HR3F=0.692433, Recall=0.823654。主候補補化。 |
| 15. interval [14,20] | Precisionはやや改善、HR3Fは[12,17]に及ばず。 |
| 16. Top-k 0.90/0.95 | 0.95は0.90より良好だが、主候補は[12,17]のまま。 |
| 17. HR3F=0.70 target search | fixed-grid 0.694491, validation 0.693450。ボトルネックはPrecision。 |

Figure 2: 本日の実験フロー後半。random baseline、F-beta、score-side grid、adaptive interval、Top-k correction、HR3F=0.70 探索まで。




Figure 3: 主要結果の概観。adaptive [12, 17] は Recall を高く維持し、HR3F を最大化する方向で最も有力である。一方、Precision は 0.60 前後で頭打ちになっている。





Figure 4: 構造遷移帯評価と random baseline 比較。点境界ではなく帯として評価することで、P²OT の大域的遷移検出能力が強く現れた。

Table 3: 本で行った主要検証の一覧

No.	検証	仮説/目的	結果・判断
1	P2OT epsilon sweep	epsilon を広げ、局所過敏を抑制	epsilon=2.0-3.0 付近で HR3F が上昇。
2	Step 1 valid/test	fold ごとの妥当性確認	epsilon=3.0 を主候補化。
3	Step 2 score separation	GT 近傍と非 GT 遠方の score 分離	fold0 で validation/test の差が大きく、以降の失敗分析対象にした。
4	fold0 failure analysis	FP/FN と分離反転の分析	GT 近傍の score 分布が高く、境界スコアが情報を持つことを確認。
5	Dual-anchor/Band-HR3F	点境界ではなく遷移帯評価へ変更	separation reversed や mixed_error が主要失敗。時刻シフト補正だけでは解決しない。
6	random band baseline	同数・同幅のランダム帯との比較	band_forward, Delta=6 が 5-fold で安定。Point baseline から大きく改善。
7	F-beta selection	Precision 制約と Recall のバランス調整	model は random distribution を大きく上回る。遷移帯評価の有効性を確認。
8	K=32 / rho sweep	クラス粒度・輸送質量の確認	beta=0.7 が Precision>=0.60 付近で HR3F を維持しやすい。
9	score-side grid	mix_lambda と expected_interval 探索	K=32 は明確な改善に至らず、K=16 主設定を維持。rho は主設定を大きく更新せず。
10	Pareto/utopia	PR 平面上の理想点を定義	lambda=0.25, interval=18 付近を主設定。interval=16 は高 Recall, 22 は高 Precision。
11	B+C+E hard filtering	relative threshold + prominence + adaptive interval	P*=0.647236, R*=0.825720 を empirical utopia として距離を計測。
12	E-only entropy	平均エントロピーで interval [16,18]	Precision は上がるが Recall が 0.565 まで落ち、構造遷移帯には hard filtering が不適。
13	Amb+Len-Var interval [16,18]	曖昧さ + 長さ-変動量で interval 決定	fixed18 より Fbeta が微改善。ただし fixed16 の高 Recall には届かず。
14	interval [12,17]	高 Recall 側へ範囲拡張	HR3F=0.690562 fixed-grid. 星印距離を改善。validation HR3F=0.692433, Recall=0.823654。主候補化。
15	interval [14,20]	Precision 回復のため広めに探索	Precision はやや改善、HR3F は [12,17] に及ばず。
16	Top-k 0.90/0.95	短 interval 曲の予測数を抑制	0.95 は 0.90 より良好だが、主候補は [12,17] のまま。
17	HR3F=0.70 target search	global に FP を削る前段階の探索	fixed-grid 0.694491, validation 0.693450。ボトルネックは Precision。

Table 4: 今日の主要設定と結果。dist は empirical utopia (P^*, R^*) = (0.647236, 0.825720) へのユークリッド距離。

設定	HR3F macro	Precision	Recall	dist
fixed18 main	0.682387	0.617101	0.764473	-
fixed16 recall-oriented	0.689776	0.593554	0.825720	0.053682
entropy adaptive [16,18]	0.684642	0.614385	0.774878	0.060532
adaptive [16,18] fixed-grid	0.690562	0.604587	0.807822	0.046252
adaptive [16,18] validation	0.689076	0.602380	0.807385	0.052211
adaptive [12,17] validation	0.692433	0.598771	0.823654	0.051619
adaptive [14,20] validation	0.688520	0.600673	0.809594	0.054942
[14,20] + Top-k 0.90	0.688595	0.604196	0.803072	0.055167
[14,20] + Top-k 0.95	0.689303	0.603940	0.805216	0.052959
[12,17] HR3F search validation	0.693450	0.582451	0.859315	-
[12,17] HR3F search fixed-grid	0.694491	0.589523	0.848227	-

**Figure 5:** Score-side grid と Pareto frontier。星印は実在する設定ではなく、最大 Precision と最大 Recall を組み合わせた empirical utopia である。




Figure 6: Entropy-only から曖昧さ・長さ・変動量に基づく adaptive interval への改善。[12, 17] は Recall と HR3F を高める方向に働いた。




Figure 7: Top-k budget correction の比較。軽い補正は Precision を改善するが、過度な補正は Recall 低下を招く。




Figure 8: HR3F=0.70 到達可能性の分析。現在の最良 Recall を維持できるなら、Precision をおよそ 0.597 まで上げれば 0.70 に近づく。

A Appendix A: 図録

以下に、今日の実験で得られた図をフェーズ別にまとめる。主本文では代表図のみを掲載したが、全体の実験経路を再確認できるよう、関連図をサムネイルとして残す。

Phase 1: epsilon, validation, score separation, fold-0 failure




Figure 9: Phase 1 図録 : epsilon sweep, validation/test, score separation, fold0 failure analysis.





Figure 10: Phase 2 図録 : Band-HR3F, random baseline, F-beta, K=32。

Phase 3: score-side grid, Pareto, adaptive interval, Top-k correction

**Figure 11:** Phase 3 図録 : score-side grid, Pareto, adaptive interval, Top-k correction.

B Appendix B: 参照

- Zhu et al., “MuQ: Self-Supervised Music Representation Learning with Mel Residual Vector Quantization.” Layout, tables, and figure-dominant academic style were used as a visual reference.
- Nieto et al., Harmonix Set and Music Structure Analysis related materials.
- P²OT: Partial Prototype Optimal Transport formulation and Sinkhorn-style implementation used in the user’s experimental pipeline.