

実験レポート 4 : P²OT 構造状態と HSMM-lite 和声状態の並列保持・統合実験

POP909 chord-type probe, code-boundary transition-band detection, γ/κ fusion, prototype harmonic grounding

田中彬
2026 年 6 月 1 日

Abstract

本レポートは、P²OT による構造状態 $\gamma_i^{(t)}$ と、HSMM-lite による和声状態 $\kappa_i^{(t)}$ を並列に保持し、POP909 における局所構造理解を検証した本日の実験結果を整理するものである。まず、oracle root-normalized 6-class chord-type probe では、P²OT $\gamma_i^{(t)}$ が Macro-F1 = 0.535402 まで到達し、コード種別情報を保持することを確認した。次に、教師なし root 推定として chord-quality template + explicit duration + Viterbi に基づく HSMM-lite を導入したところ、hard root-normalization + P²OT $\gamma_i^{(t)}$ で Macro-F1 = 0.441330 となり、 P_{raw} の 0.406908 を上回った。一方、naive soft root-normalization は Macro-F1 = 0.358417 に低下し、root posterior を chroma 回転に直接混合すると和声音程構造をばかす可能性が示された。さらに $(\gamma_i^{(t)}, \kappa_i^{(t)})$ の単純連結は $\gamma_i^{(t)}$ 単体を上回らなかったため、 $\kappa_i^{(t)}$ は分類特徴ではなく、P²OT prototype の harmonic grounding に用いる方針が有力である。さらに、P²OT の局所変化量 $\delta_i^{(t)}$ と自己距離行列由来の周辺変化量 $\nu_{A,i}^{(t)}$ を用いたコード境界遷移帯検知プロトコルを定式化し、関連する遷移帯検知実験では adaptive [12, 17] fixed-grid が $\text{HR3F}_{\text{macro}} = 0.694491$ に到達したことを整理した。POP909 chord-change boundary detection については、Chord-change Hit Rate, Event-F1, AUPRC を主指標として実測値を追加した。特に $K = 16, \ell = 1, \lambda = 0.25, \tau = 0.5$ の設定で、 $\varepsilon = 2.0$ が $\text{AUPRC} = 0.715284, \text{Event-F1}_{\text{micro}} = 0.682937, \text{HitRate}_{\text{macro}} = 0.850622$ を示し、 ε の調整が P²OT のズームイン/ズームアウト制御に相当することを明記した。最後に、family-size 補正と global prior 補正を用いた prior-corrected lift により、128 個の prototype は maj=38, min=14, seventh=30, sus=18, dim=28 に分散し、P²OT の構造状態に相対的な和声の意味付けを与えられる可能性を確認した。

Keywords: Music Information Retrieval, P²OT, HSMM, chord-type probe, prototype grounding, root-normalization

1 背景と目的

前回までの実験では、P²OT を点境界検出器ではなく、解像度可変な構造レンズとして扱う方針を確認した。本日の課題は、そのズームイン側の検証として、POP909 の chord-type 情報を P²OT 表現からどの程度読み出せるか、さらに HSMM 的な root/chord 推定をどのように併用できるかを調べることである。

特に、oracle root-normalization により chord-type probe が大きく改善したため、低性能の主因は P²OT 表現の欠如ではなく、root 差による chord quality 情報の分散である可能性が高くなった。そこで本実験では、教師なし root 推定として HSMM-lite を導入し、P²OT branch と HSMM branch の並列利用を検証した。

2 記法とモデル構成

2.1 P²OT structural branch

各時刻の入力特徴を $x_i^{(t)}$ とする。完成形では

$$z_i^{(t)} = f_{\text{MuQ}}(x_i^{(t)}), \quad h_i^{(t)} = f_{\text{Tr}}(z_i^{(1:T_i)}) \quad (1)$$

により共通の文脈表現 $h_i^{(t)}$ を得る。その後、P²OT branch は

$$h_i^{(t)} \rightarrow \text{P}^2\text{OT} \rightarrow \gamma_i^{(t)} \in \Delta^{K-1} \quad (2)$$

を生成する。本日の軽量実験では、リソース削減のため Transformer ではなく chroma/root-normalized chroma を用いたが、役割としては $\gamma_i^{(t)}$ を構造状態分布として扱う。

prototype c_k への素朴な割当確率は

$$D_{t,k} = \|x_i^{(t)} - c_k\|^2, \quad (3)$$

$$P_{\text{raw}_i}^{(t,k)} = \frac{\exp(-D_{t,k}/\tau)}{\sum_{k'} \exp(-D_{t,k'}/\tau)} \quad (4)$$

である。P²OT は、この P_{raw} に対して prototype 使用量の偏りを制御する再配分を行う。実験では $K = 128, \varepsilon = 6.0, \rho = 0.7$ を主設定とした。


2.2 HSMM-lite harmonic branch

HSMM-lite branch は、chord-quality template、明示的 duration、Viterbi 推定により、root と quality の系列を推定する。本実験では

$$\kappa_i^{(t)} \in \Delta^{12Q-1}, \quad Q = 7 \quad (5)$$

本日の結論

- 主表現は P²OT の $\gamma_i^{(t)}$ とする。
- HSMM-lite の $\kappa_i^{(t)}$ は、現時点では分類特徴として直接連結するより、prototype の意味付けに使う方が有効である。
- naive soft root-normalization は和声音程構造をばかすため、hard root 推定の方が良かった。
- raw grounding は seventh に偏るため、正式な grounding は prior-corrected lift を用いる。



This report keeps gamma as the main structural representation and uses kappa primarily for harmonic grounding.

Figure 1: 本日の軽量検証における P²OT branch と HSMM-lite branch の関係。 $\gamma_i^{(t)}$ は構造状態、 $\kappa_i^{(t)}$ は和声状態として保持する。

を、root $r \in \{0, \dots, 11\}$ と quality $q \in \{\text{maj}, \text{min}, \text{dim}, \text{dom7}, \text{maj7}, \text{min7}, \text{sus}\}$ の状態として定義した。hard 版では

$$\hat{r}_i^{(t)} = \arg \max_r p(r_i^{(t)} = r \mid x_i^{(1:T_i)}) \quad (6)$$

により root を 1 つ選び、

$$\tilde{x}_i^{(t)}[k] = x_i^{(t)}[(k + \hat{r}_i^{(t)}) \bmod 12] \quad (7)$$

で root-normalization を行う。
soft 版では root posterior を用いて

$$\tilde{x}_i^{(t)} = \sum_{r=0}^{11} p(r_i^{(t)} = r \mid x_i) R_{-r} x_i^{(t)} \quad (8)$$

を作る。ただし本実験では、式 (8) は複数 root の回転を混合するため、和声音程構造をばかす可能性があることが確認された。

2.3 γ/κ 並列統合

完成形の構想は、共通上流表現の後に P²OT branch と HSMM branch が枝分かれする構造である。図1に本日の軽量検証の実装対応を示す。

単純な late fusion では

$$\Omega_i^{(t)} = [\gamma_i^{(t)}, \kappa_i^{(t)}] \quad (9)$$

を分類器に入力した。しかし本日の結果では、 $\kappa_i^{(t)}$ の直接連結は性能を改善しなかった。

3 実験設定

Table 1: 主な実験設定

項目	値
データセット	POP909 subset, 100 songs
フレーム長	1.0 sec
root/chord branch	HSMM-lite
HSMM-lite 構成	chord template + duration + Viterbi
P ² OT prototype 数	$K = 128$
P ² OT epsilon	$\varepsilon = 6.0$
Sinkhorn iteration	80
分類タスク	6-class chord type
6-class	maj/min/seventh/sus/dim/other
seventh	maj7, min7, dom7
評価分割	GroupKFold by song, 5 folds
分類器	Logistic Regression, MLP

Table 2: 使用ライブラリと用途

ライブラリ	用途
NumPy	chroma, γ , κ , lift 計算
Pandas	CSV 集計、fold 結果表、prototype 表の保存
Matplotlib	棒グラフ、ヒートマップ、比較図の作成
scikit-learn	Logistic Regression, GroupKFold, StandardScaler
pretty_midi	POP909 MIDI から chroma 生成
tqdm	100 曲処理の進行表示
PyTorch	MLP probe の実装
XeLaTeX	二段組レポート PDF の作成

4 Oracle root-normalized chord-type probe

まず、正解 root を使う oracle diagnostic probe を上限として確認した。6 分類では rootnorm P²OT $\gamma_i^{(t)}$ が chroma より Macro-F1 と Balanced Accuracy でわずかに優位であった。

この結果は、P²OT $\gamma_i^{(t)}$ が chord-type 情報を保持していることを示す。一方で、この条件は正解 root を使用しているため、実運用では教師なし root 推定が必要となる。

Table 3: Oracle root-normalized 6-class chord-type probe

表現・分類器	Accuracy	Balanced Acc.	Macro-F1	Weighted-F1
rootnorm chroma / LogReg	0.713170	0.690508	0.523790	0.764827
rootnorm P_{raw} / LogReg	0.699785	0.656557	0.508983	0.755964
rootnorm P ² OT γ / LogReg	0.701673	0.694103	0.535402	0.757574
rootnorm P ² OT γ / MLP	0.700987	0.689283	0.535635	0.755664

5 HSMM-lite による教師なし root-normalization

5.1 Hard root-normalization

HSMM-lite による root 推定精度は平均 0.468468 であった。12 root のランダム推定が $1/12 \simeq 0.083$ であることを考えると、root 情報は一定程度取得できている。

Table 4: HSMM-lite hard root-normalization の結果

表現	Acc.	BalAcc	Macro-F1	W-F1
chroma	0.448609	0.449141	0.299840	0.489455
P_{raw}	0.623260	0.535528	0.406908	0.683195
P ² OT γ	0.640240	0.586902	0.441330	0.694910

重要なのは、P²OT $\gamma_i^{(t)}$ が P_{raw} を上回った点である。

$$\text{Macro-F1} : 0.406908 \rightarrow 0.441330. \quad (10)$$

これは、不完全な教師なし root-normalization 後でも、P²OT が prototype assignment を構造化し、chord-type 情報を読み出しやすくする可能性を示す。

5.2 Soft root-normalization

soft root posterior の平均信頼度は 0.693352、平均 entropy は 0.937094 であった。しかし、soft rootnorm P²OT $\gamma_i^{(t)}$ の結果は

$$\begin{aligned} \text{Accuracy} &= 0.543217, \quad \text{BalancedAcc} = 0.495650, \\ \text{Macro-F1} &= 0.358417, \quad \text{Weighted-F1} = 0.610569. \end{aligned} \quad (11)$$

となり、hard rootnorm の Macro-F1 = 0.441330 を下回った。

これは、root posterior を chroma 回転の重みとして混合すると、major/minor/seventh などの音程構造が平均化され、分類に必要な和声形状がぼけるためと考えられる。




Figure 2: Oracle, hard HSMM-lite, soft HSMM-lite の chord-type probe 比較。soft root-normalization は hard 版より低下した。

6 コード境界遷移帯検知の定式化

6.1 目的

本レポート 4 では、chord-type probe に加えて、次段階のズームイン評価としてコード境界遷移帯の検知プロトコルを追加する。ここでの目的は、単一フレームを厳密な境界点として当てるのではなく、コード変化の前後で現れる構造的な遷移帯を P²OT の構造スコアから検出することである。

POP909 の chord annotation から、曲 i の正解コード変化時刻集合を

$$\mathcal{C}_i = \{c_{i,m} \mid y_i^{(t_m)} \neq y_i^{(t_m-1)}\} \quad (12)$$

とする。P²OT の出力 $\gamma_i^{(t)}$ から、局所変化量、自己距離行列、周辺変化量を次のように定義する。

6.2 統一記法による構造スコア

局所変化量は隣接時刻の確率状態の変化として

$$\delta_i^{(t)} = d_{\sqrt{JS}}(\gamma_i^{(t+1)}, \gamma_i^{(t)}) \quad (13)$$

で定義する。自己距離行列は

$$\mathcal{A}_i(t, s) = d_{\sqrt{JS}}(\gamma_i^{(t)}, \gamma_i^{(s)}) \quad (14)$$

である。平均確率状態による周辺変化量は、窓幅 ℓ を用いて

$$\nu_i^{(t)} = \frac{1}{2\ell} \sum_{u=1}^{\ell} \left\{ d_{\sqrt{JS}}(\gamma_i^{(t)}, \gamma_i^{(t-u)}) + d_{\sqrt{JS}}(\gamma_i^{(t)}, \gamma_i^{(t+u)}) \right\} \quad (15)$$

とする。さらに、自己距離行列由来の周辺変化量は、自己距離行列の行ベクトル差により

$$\nu_{\mathcal{A},i}^{(t)} = \frac{1}{2\ell} \sum_{u=1}^{\ell} \frac{1}{T_i} \|\mathcal{A}_i(t+u, :) - \mathcal{A}_i(t-u, :)\|_1 \quad (16)$$

と定義する。これにより、単なる隣接変化ではなく、曲全体に対する構造的な位置の変化を評価できる。

各系列を曲内で min-max 正規化し、

$$\tilde{z}_i^{(t)} = \frac{z_i^{(t)} - \min_t z_i^{(t)}}{\max_t z_i^{(t)} - \min_t z_i^{(t)} + \epsilon} \quad (17)$$

とする。コード境界遷移帯検知に用いる混合スコアは、既存の統一表記に合わせて

$$S_{\lambda,i}^{(t)} = (1-\lambda)\tilde{\nu}_{\mathcal{A},i}^{(t)} + \lambda\tilde{\delta}_i^{(t)} \quad (18)$$

で定義する。 λ が大きいほど隣接フレームの局所変化を重視し、 λ が小さいほど自己距離行列から見た周辺構造変化を重視する。




Figure 3: コード境界遷移帯検知の模式図。 $S_{\lambda,i}^{(t)}$ のピークと、正解コード変化時刻の周辺 $\pm\tau$ 秒帯を比較する。

6.3 点境界ではなく遷移帯として評価する理由

コード変化は annotation 上は一点として与えられるが、実際の音響・MIDI 表現では、直前の準備音、保持音、アルペジオ、ペダル、非和声音により、変化は数フレームにまたがることが多い。そのため、本研究では予測点 $\hat{t}$ を直接正解点 c と比較するだけでなく、

$$B(c; \tau) = [c - \tau, c + \tau] \quad (19)$$

を正解遷移帯として扱う。予測側も、閾値 θ または top- K_i により

$$\hat{P}_i(\theta) = \{t \mid S_{\lambda,i}^{(t)} \geq \theta\} \quad (20)$$

を取り、隣接する予測点を結合して予測遷移帯 $\hat{B}_i$ として扱う。

6.4 評価指標

Chord-change Hit Rate は、正解 chord change が少なくとも 1 つの予測遷移帯に含まれた割合として

$$\text{HR}_\tau = \frac{1}{\sum_i |\mathcal{C}_i|} \sum_i \sum_{c \in \mathcal{C}_i} \mathbf{1}[\exists \hat{b} \in \hat{B}_i, c \in \hat{b}] \quad (21)$$

で定義する。Event-F1 は、 $\pm\tau$ 秒以内の的一对一 matching により true positive, false positive, false negative を数え、

$$\text{Event-F1}_\tau = \frac{2\text{TP}_\tau}{2\text{TP}_\tau + \text{FP}_\tau + \text{FN}_\tau} \quad (22)$$

で評価する。AUPRC は、 $S_{\lambda,i}^{(t)}$ の閾値 θ を掃引し、 τ 秒以内を positive frame として precision-recall curve の面積で評価する。

Table 5: コード境界遷移帯検知の評価プロトコル

項目	内容
入力表現	P ² OT $\gamma_i^{(t)}$ 、主に hard HSMM-lite rootnorm + $K = 128, \varepsilon = 6.0$
構造量	$\delta_i^{(t)}, \nu_i^{(t)}, \nu_{A,i}^{(t)}, A_i(t, s)$
混合スコア	$S_{\lambda,i}^{(t)} = (1 - \lambda)\tilde{p}_{A,i}^{(t)} + \lambda\tilde{\delta}_i^{(t)}$
正解境界	POP909 chord annotation の chord label 変化時刻
評価単位	点境界と $\pm\tau$ 秒の遷移帯を併用
指標	Chord-change Hit Rate, Event-F1 $_\tau$, AUPRC
注意	具体的な既存遷移帯検知結果を表6に整理する

6.5 境界遷移帯検知の定量結果

本レポートで定式化したコード境界遷移帯検知は、前段階の楽曲構造遷移帯検知実験で用いた Band-HR3F の考え方を POP909 の chord change に移すものである。したがって、まず既に実測済みの遷移帯検知結

果を表6に整理する。いずれも予測を一点境界ではなく band として扱い、正解境界が予測帯に含まれるかを評価した結果である。

表6より、遷移帯幅を固定するだけでなく、楽曲ごとに adaptive interval を変えることで HR3F が改善したことが分かる。特に adaptive [12,17] は Recall を高く維持し、HR3F_{macro} = 0.694491 まで到達した。一方で Precision は 0.58–0.61 程度であり、HR3F=0.70 到達には過検出を抑える Top-k budget correction や precision 制約付き選択が必要である。POP909 の chord change 検知では、この結果を基準として、式 (18) の $S_{\lambda,i}^{(t)}$ に対して Chord-change Hit Rate, Event-F1 $_\tau$, AUPRC を実測する。

6.6 POP909 chord-change boundary detection の実測結果

POP909 の chord-change boundary detection では、正解コードラベルの変化時刻 $\mathcal{C}_i$ に対して、P²OT から得られる $S_{\lambda,i}^{(t)}$ のピークまたは予測帯がどの程度一致するかを評価する。主指標は Chord-change Hit Rate, Event-F1, AUPRC とする。表7に、 $K = 16, \rho = 0.7, \lambda_{KL} = 1.0, \text{frame} = 1.0 \text{ s}, \ell = 1, \lambda = 0.25, \tau = 0.5, \text{top-k interval} = 1.5 \text{ s}, \text{min-gap} = 1.0 \text{ s}$, 100 曲での ε sweep 結果を示す。ここでは $\varepsilon = 0.8, 1.0, 2.0, 2.25, 2.5, 2.75, 3.0$ の全 7 行を掲載する。

表7より、AUPRC は $\varepsilon = 2.0$ で最大値 0.715284 を取り、EventF1 micro, Precision, Recall は $\varepsilon = 2.75$ で最大となった。また HitRate macro は $\varepsilon = 3.0$ で最大値 0.852762 を示した。一方で Entropy は $\varepsilon = 0.8$ の 0.248202 から $\varepsilon = 3.0$ の 0.772429 まで単調に増加しており、 ε を大きくするほど P²OT の割当てが soft 化し、より広い遷移帯を捉える zoom-out 側へ移ることが確認できる。したがって、POP909 の chord-change boundary detection では、鋭い zoom-in よりも、 $\varepsilon = 2.0$ – 3.0 程度の中程度からやや zoom-out 側の設定が有効である。

ここで ε は P²OT の解像度を制御するパラメータとして扱う。小さい ε では輸送が鋭くなり、局所的な prototype assignment の変化を保持しやすいため、コード変化直前・直後の細かな差分を拾う zoom-in 設定に相当する。一方、大きい ε では割当てが平滑化され、微小な揺れよりも広い遷移帯や大域的な構造変化を拾いやすくなるため、zoom-out 設定に相当する。したがって、本研究における ε sweep は単なる数値安定化ではなく、P²OT を解像度可変な構造レンズとして用いるための実験操作である。

6.7 本日の結果との接続

本日の chord-type probe では、hard HSMM-lite rootnorm + P²OT $\gamma_i^{(t)}$ が Macro-F1 = 0.441330 であり、 P_{raw} を上回った。したがってコード境界遷移帯検知では、まずこの $\gamma_i^{(t)}$ を主表現とし、式 (18) の $S_{\lambda,i}^{(t)}$ から transition-band score を作るのが自然である。一方、 $\kappa_i^{(t)}$ は分類特徴として直接連結するより、prototype grounding や chord family の補助解釈として使う。

Table 6: 境界遷移帯検知の実験結果。adaptive [12, 17] が現時点の最高値であり、HR3F=0.70 目標に最も近い。

設定	遷移帯・budget 設計	HR3F _{macro}	Precision	Recall
fixed18 main	fixed interval = 18 s	0.682387	0.617101	0.764473
fixed16 recall-oriented	fixed interval = 16 s	0.689776	0.593554	0.825720
adaptive 14-20 + Top-k 0.95	interval 14-20, $K_i \times 0.95$	0.689303	0.603940	0.805216
adaptive 12-17 validation	interval 12-17, validation-selected	0.693450	0.582451	0.859315
adaptive 12-17 fixed-grid	interval 12-17, fixed-grid best	0.694491	0.589523	0.848227

Table 7: POP909 chord-change boundary detection における P²OT ϵ sweep の実測結果 (全 7 条件)。AUPRC は $S_{\lambda,i}^{(t)}$ に基づく frame-level PR-AUC、EventF1 は micro 平均、HitRate は Chord-change Hit Rate の macro 平均である。


ϵ	AUPRC($S_{\lambda,i}^{(t)}$)	EventF1 micro	HitRate macro	Precision	Recall	Entropy
0.8	0.704909	0.678829	0.845767	0.585666	0.807237	0.248202
1.0	0.711204	0.679177	0.845911	0.585967	0.807651	0.311083
2.0	0.715284	0.682937	0.850622	0.589211	0.812122	0.596019
2.25	0.713639	0.683842	0.851885	0.589992	0.813199	0.650696
2.5	0.711854	0.683494	0.851562	0.589691	0.812785	0.697895
2.75	0.710332	0.684190	0.852344	0.590292	0.813613	0.738209
3.0	0.709036	0.684121	0.852762	0.590232	0.813530	0.772429

7 γ/κ parallel fusion

7.1 単純連結の検証

P²OT の構造状態 $\gamma_i^{(t)}$ と HSMM-lite の和声状態 $\kappa_i^{(t)}$ を単純連結して分類器に入力した。

結果として、単純連結はいずれも γ only を上回らなかった。したがって、現時点の $\kappa_i^{(t)}$ は分類特徴として直接使うより、P²OT prototype の意味付けに使う方が妥当である。

**Figure 4:** γ/κ fusion の Macro-F1 比較。単純連結は γ only を改善しなかった。

7.2 解釈

$\kappa_i^{(t)}$ が低性能だった理由は、HSMM-lite の root/quality 推定がまだ粗く、one-hot で分類器に入力するとノイズ特徴として作用するためである。したがって本研究では、

$$\gamma_i^{(t)} : \text{主表現・構造状態} \quad (23)$$

$$\kappa_i^{(t)} : \text{補助解釈・prototype grounding} \quad (24)$$

と役割分担する。

8 Prototype harmonic grounding


8.1 Raw grounding

P²OT prototype a の和声的意味付けとして、

$$\kappa_a(r, q) = \frac{\sum_t \gamma_a^{(t)} \kappa^{(t)}(r, q)}{\sum_t \gamma_a^{(t)} + \epsilon} \quad (25)$$

を構成した。

まず raw aggregation では、全 128 prototype が seventh family に割り当てられた。図5は、raw grounding における seventh への強い偏りを示す。この結果は P²OT 側の性質というより、HSMM-lite κ 側が min7/maj7/dom7 を出しやすい global bias を持つことを示す。

**Figure 5:** Raw grounding による family 割当。全 prototype が seventh に割り当てられた。

8.2 Prior-corrected lift

raw score の偏りを補正するため、family-size 補正と global prior 補正を導入した。まず quality score を root 方向に集約し、family f の score は所属 quality

Table 8: $\gamma_i^{(t)}$ と $\kappa_i^{(t)}$ の並列統合結果

表現	Accuracy	Balanced Acc.	Macro-F1	Weighted-F1
γ only / P ² OT structure	0.640240	0.586902	0.441330	0.694910
κ_{84} only / HSMM harmony	0.193967	0.299710	0.155897	0.227807
κ_{19} only / factorized HSMM	0.190272	0.295757	0.160341	0.207051
$[\gamma, \kappa_{84}]$	0.627705	0.547102	0.417670	0.684856
$[\gamma, \kappa_{19}]$	0.635679	0.572425	0.429432	0.691570

の平均として定義した。

$$P_a(f) = \frac{1}{|Q_f|} \sum_{q \in Q_f} P_a(q). \quad (26)$$

次に、全 prototype 上の family prior を

$$\pi_f = \frac{1}{K} \sum_{a=1}^K P_a(f) \quad (27)$$

とし、prior-corrected lift を

$$\text{lift}_a(f) = \frac{P_a(f)}{\pi_f + \epsilon} \quad (28)$$

で定義した。これは、全体平均と比べて prototype a が family f にどれだけ相対的に寄っているかを表す。

補正前の family prior は


$$\pi_{maj} = 0.007349, \quad \pi_{min} = 0.006453, \quad \pi_{seventh} = 0.304928, \quad (29)$$

$$\pi_{sus} = 0.070512, \quad \pi_{dim} = 0.000901 \quad (30)$$

であり、seventh に強い全体バイアスがあることが確認された。

Table 9: Prior-corrected family assignment

Family	Prototype 数
maj	38
min	14
seventh	30
sus	18
dim	28

**Figure 7:** Prior-corrected lift による family 割当。raw grounding の seventh 一極集中が解消された。

8.3 代表 prototype

補正版 grounding による代表例を表10に示す。これらは絶対的なコードラベルではなく、全体平均に対して相対的にその harmonic family へ寄る prototype と解釈する。

Table 10: Family ごとの上位 prototype 例

Family	上位 prototype 例
maj	P122, P31, P95, P40, P73
min	P122, P32, P80, P102, P14
seventh	P108, P12, P39, P111, P45
sus	P5, P88, P67, P83, P121
dim	P122, P80, P32, P100, P4

9 考察

9.1 なぜ soft root-normalization は下がったか

soft root-normalization は root posterior を用いるため一見安定しそうだが、chroma 回転を確率的に混合すると、root が異なる複数の和声形状が平均される。これは、major third や minor third、seventh などの相対音程構造をぼかす。そのため、posterior は root-normalization の直接重みとして使うより、信頼度や $\kappa_i^{(t)}$ として並列保持する方がよい。

9.2 なぜ κ の単純連結は効かなかったか

HSMM-lite の root accuracy は 0.468468 であり、 $\kappa_i^{(t)}$ には誤りが含まれる。これを one-hot で分類器へ直接入力すると、 $\gamma_i^{(t)}$ の安定した構造表現にノイズを混入させる可能性がある。したがって、 $\kappa_i^{(t)}$ は分類性能向上ではなく、P²OT prototype の意味付けに使う方が適切である。

9.3 P²OT の位置づけ

本日の結果から、P²OT は chord classifier そのものではなく、構造状態分布を与える主表現であると整理できる。HSMM-lite は root/chord の補助推定器であり、その出力は global bias を補正したうえで harmonic grounding に用いる。この役割分担により、構造理解と和声的意味付けを分離しながら統合できる。

10 今後の方針

次に進めるべき方向は以下である。

1. 本レポートで実測した POP909 chord-change boundary detection を、 $\epsilon = 0.8, 1.0, 2.0$ から $\epsilon = 3.0, 4.0, 6.0$ へ拡張し、最適な zoom 水準をさらに探索する。
2. $\kappa_i^{(t)}$ は direct fusion ではなく、prior-corrected prototype grounding として正式採用する。

3. HSMM-lite の改良として、root transition、duration prior、template family の重みを学習可能にする。
4. $[\gamma_i^{(t)}, c_i^{(t)}, \kappa_i^{(t)}]$ のような confidence-gated fusion を追加検証する。
5. 完成形では、MuQ $\rightarrow$ Transformer 後の $h_i^{(t)}$ を P²OT branch と HSMM branch に渡し、HSMM 側は chroma 観測を主、 $h_i^{(t)}$ を補助条件として使う。

11 結論

本日の実験では、P²OT の構造状態 $\gamma_i^{(t)}$ と HSMM-lite の和声状態 $\kappa_i^{(t)}$ の関係を検証した。hard HSMM-lite root-normalization + P²OT $\gamma_i^{(t)}$ は Macro-F1 = 0.441330 を達成し、 P_{raw} を上回った。一方、soft root-normalization と $[\gamma, \kappa]$ の単純連結は改善しなかった。したがって、現段階では

$$\boxed{\gamma_i^{(t)} = \text{主表現}} \quad (31)$$

$$\boxed{\kappa_i^{(t)} = \text{prior-corrected harmonic grounding}} \quad (32)$$

として扱うのが最も妥当である。

特に、prior-corrected lift により prototype 割当てが maj=38, min=14, seventh=30, sus=18, dim=28 に分散したことは、P²OT prototype に対し、全体バイアスを補正した相対的和声意味を付与できる可能性を示している。また、コード境界遷移帯検知については、 $\delta_i^{(t)}, \nu_{\mathcal{A},i}^{(t)}, \mathcal{A}_i(t, s), S_{\lambda,i}^{(t)}$ を用いた評価プロトコルに加え、POP909 100 曲で $\varepsilon = 2.0$ が AUPRC=0.715284, Event-F1_{micro} = 0.682937, HitRate_{macro} = 0.850622 を示す実測表を追加した。これは、P²OT を「構造レンズ」として用い、HSMM-lite を「和声意味付け器」として用いる並列構造の有望性を、分類評価と境界遷移帯評価の双方から検証するための基盤である。

References

- [1] P²OT 関連論文. Prototype-oriented partial optimal transport に基づく不均衡表現学習.
- [2] MuQ: Music foundation model / music representation learning paper.
- [3] Hidden semi-Markov model based chord / root / duration modeling paper.
- [4] O. Nieto et al., "Audio-Based Music Structure Analysis: Current Trends, Open Challenges, and Applications," 2020.




Figure 6: Raw grounding heatmap. seventh column が支配的であり、補正なしでは prototype 固有の和声傾向を読み取りにくい。




Figure 8: Prior-corrected lift heatmap. 各 prototype が全体平均に対して相対的にどの family に寄っているかを示す。




Figure 9: 各 harmonic family に対する prior-corrected lift 上位 prototype。sus と dim では特に lift が高く、全体 prior が低い family で相対的特徴が見えやすい。