

時系列的楽曲構造理解のための表現基盤構築

研究計画書

2026 年 5 月 29 日

1. Introduction

近年、音楽を取り巻く環境は大きく変化している。SNS およびストリーミングサービスの普及により、ユーザは従来よりも大規模な楽曲ライブラリに容易にアクセスできるようになり、音楽消費の量および多様性は拡大している。Datta et al. は、音楽ストリーミングの導入が消費量および消費多様性の増加をもたらすことを示しており、ストリーミング環境の普及は音楽聴取行動そのものを変化させていると考えられる [1]。

また、制作環境および配信環境の低コスト化により、個人や小規模なアーティストであっても楽曲を公開できるようになった。Luminate の 2024 年報告に基づく Music Business Worldwide の記事では、2024 年には 1 日平均約 99,000 曲が新規アップロードされ、そのうち 91.8% がインディペンデント系ディストリビュータ経由であったと報告されている [2]。さらに Spotify の Loud & Clear FAQ によると、Spotify には少なくとも 1 曲をアップロードした人が約 1,300 万人存在し、そのうち約 800 万人は合計 10 曲未満のリリースにとどまっている [3]。このことは、音楽配信環境において、プロフェッショナルな大規模アーティストだけでなく、多数の小規模・新規アーティストが流通空間に参加していることを示している。

このような状況では、音楽推薦や音楽理解において扱うべき楽曲空間は大規模化し、かつ多様化している。一方で、現代の楽曲は単一のジャンルラベルに還元しにくい。音楽ジャンルは、音響的特徴だけでなく、文化的背景、聴取者コミュニティ、時代性、社会的文脈によって形成される多面的な概念である。Sordo et al. は、専門家によるジャンル分類とユーザコミュニティによるタグ付けが必ずしも一致しないことを示しており、ジャンル分類が固定的・一義的な体系ではないことを示唆している [4]。したがって、特に複数のジャンルの特徴を併せ持つ楽曲や、時間的に大きく展開する楽曲では、単一ジャンルへの分類だけでは楽曲の特徴を十分に捉えられない可能性がある。

さらに、現在の音楽推薦では、協調フィルタリングが代表的な手法の一つとして用いられている。しかし、協

調フィルタリングはユーザの聴取履歴や評価履歴に基づいて推薦を行うため、十分な相互作用データを持つ人気アーティストや既存楽曲に対して有効に働きやすい一方で、新規アーティストやロングテール楽曲ではデータ疎性や cold-start 問題が生じやすい。Kowald, Schedl, and Lex は、Last.fm データを用いて、音楽推薦において人気アイテムが推薦されやすく、特に主流音楽から離れた嗜好を持つユーザが相対的に悪い推薦を受けやすいことを示している [5]。また、Mansoury et al. は、推薦されたアイテムがユーザに消費され、その履歴が再び推薦モデルに取り込まれることで人気バイアスが増幅され、推薦多様性の低下、ユーザ嗜好表現の変化、ユーザ体験の均質化が生じる可能性を示している [6]。

楽曲を構造的に理解する重要性は、Music Structure Analysis 研究においても指摘されている。Nieto et al. は、audio-based Music Structure Analysis を楽曲内容の高次の map あるいは outline として位置づけ、大規模音楽カタログの理解、探索、推薦、音楽生成、音楽制作支援などに応用可能であると述べている [7]。一方で、同研究は、楽曲構造には主観性、曖昧性、階層性が存在し、より豊かな構造記述が今後の課題であることも指摘している。さらに MIREX 2025 Music Structure Analysis Task では、楽曲構造理解が国際的な評価タスクとして継続して扱われており、近年は A/B/C のような抽象的構造ラベルではなく、intro, verse, chorus などの機能的構造ラベルを推定する方向へ発展している [8]。したがって、楽曲を単なる静的特徴ベクトルや単一ジャンルラベルとして扱うのではなく、時間的に展開する構造体として表現する情報基盤の構築は、現代の音楽情報処理において重要な課題である。

近年の MSA における本研究の位置づけ

近年の Music Structure Analysis (MSA) では、いくつかの主要な研究動向が見られる。第一に、従来の MSA は、楽曲を A/B/C のような抽象的なセクションへ分割することに重点を置いていたが、近年は intro, verse,

chorus, bridge, outro などの機能的構造ラベルを推定する方向へ発展している。MIREX 2025 Music Structure Analysis Task においても, musical form の理解は音楽理解の基礎であり, 多くの音楽情報検索応用において重要であるとされている [8]。本研究では, 機能的構造ラベルを直接教師あり分類することを主目的とするのではなく, 楽曲を確率単体上の特徴確率経路として記述することで, 時間的展開の解釈性を高める。さらに, 自己距離行列を用いて, 局所変化, 反復, 再訪, 全体構造を同一表現から考察し, 機能的構造を幾何的に捉えるための表現基盤を構築する。

第二に, 近年の MSA では, 拍, ダウンビート, セクション境界, 機能的構造ラベルを個別に扱うのではなく, 音楽の階層的構造を統合的に扱う All-in-One 型の構造理解が提案されている [9]。本研究は, beat tracking や downbeat tracking を直接同時推定する All-in-One モデルそのものを構築するものではない。しかし, 楽曲を一定時間幅のセグメント列として扱い, 各区間の特徴を時系列的に記述することで, 局所の変化と大域的展開を同一の表現上で扱うことを目指す。これにより, 将来的に拍・小節・セクションなどの異なる時間スケールを統合する階層的構造理解へ拡張可能な基盤を与える。

第三に, 近年は音楽基盤モデルや音響基盤モデルを MSA に適応する研究も進んでいる [10, 11]。事前学習済み基盤モデルは強力な音響表現を獲得できる一方で, 多くは短い音声窓を前提として学習されており, フル尺楽曲の長時間構造を扱う際には時間的適応が課題となる。本研究では, MuQ などの事前学習済み音楽表現モデルから得られる時系列特徴を用い [12], それをそのまま分類に用いるのではなく, (P²OT) による深層クラスタリングと確率単体上の soft assignment によって [13], 楽曲の時間的狀態遷移を特徴確率経路として表現する。

第四に, 近年の MSA では, self-similarity matrix や graph attention に基づき, 楽曲内の時点間関係を学習する研究も現れている [14, 15]。本研究でも, 各楽曲に対して自己距離行列を構成し, 時点間関係を明示的に扱う。これにより, 単なる隣接時刻間の変化だけでなく, 離れた区間同士の反復, 再訪, 対比, 構造的類似性を捉えることを目指す。

以上より, 本研究は, 近年の MSA における機能的構造理解, 階層的構造理解, 音楽基盤モデルの活用, 時点間関係の学習という流れを踏まえつつ, 構造ラベルを直接推定するのではなく, 楽曲を特徴確率経路として表現し,

平均的特徴, 時間的展開, 内部自己構造の三側面から比較可能にする表現基盤を構築する点に特徴がある。

以上を踏まえると, 音楽推薦および音楽理解においては, ユーザ行動履歴や単一ジャンルラベルのみに依存するのではなく, 楽曲そのものが持つ内容的・構造的特徴を捉える表現が重要である。特に楽曲は時間とともに展開する芸術であり, イントロ, A メロ, B メロ, サビ, ドロップ, 間奏, アウトロなどの各部分が相互に関係しながら, 全体として一つのストーリー性を形成している。そのため, 楽曲を単なる静的な特徴ベクトルや分類ラベルとして扱うのではなく, 時間的に展開する構造体として捉える必要がある。

そこで本研究では, 楽曲そのものが持つ時間的展開, 反復構造, 状態遷移, 緊張と解放といった構造的特徴に着目する。具体的には, 事前学習済み音楽表現モデルから得られる時系列特徴を用いて, 各区間の音楽的狀態を確率分布として表現し, 楽曲全体を特徴確率経路として記述する。これにより, 楽曲を単一のジャンルや感情ラベルへ還元するのではなく, 時間に沿って変化する音楽的狀態の軌跡として表現する。

さらに, 楽曲間の比較においては, 平均的な特徴の近さだけでなく, 時間的な展開の類似性および楽曲内部の自己構造の類似性を考慮する。具体的には, 平均分布に基づく比較, DTW- $\sqrt{JS}$ 距離による特徴確率経路の比較, 自己距離行列に基づく構造比較を組み合わせることで, 楽曲を単なる分類対象ではなく, 時間的に展開する構造体として理解するための枠組みを構築する。

2. Method / Approach

本章では, 本研究で用いる時系列的楽曲構造理解のための表現生成手順を定式化する。提案手法は, 音響信号の 5 秒分割, MuQ による区間特徴抽出, Transformer による文脈化, (P²OT) による不均衡対応型 soft assignment, 特徴確率経路と自己距離行列の構成, および三項評価による楽曲間比較から構成される。

2.1 5 秒窓による音響信号の分割

楽曲 i の音響信号を x_i , 曲長を L_i 秒とする。本研究では, 楽曲 x_i を 5 秒幅の時間窓へ分割し, 末尾の区間は 5 秒未満であっても一つの区間として扱う。区間数を

$$T_i = \left\lceil \frac{L_i}{5} \right\rceil \quad (1)$$

とし、第 t 区間を

$$x_i^{(t)} = x_i[5(t-1), \min(5t, L_i)] \quad (2)$$

と表す。したがって、楽曲 i は

$$x_i = (x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(T_i)}) \quad (3)$$

という時間区間列として扱われる。5 秒窓を用いる理由は、フレーム単位の微細な音響ゆらぎではなく、区間単位の音楽的状态や構造的変化を捉えるためである。

2.2 MuQ による区間特徴抽出

各区間 $x_i^{(t)}$ に対して、事前学習済み音楽表現モデル MuQ を適用する。MuQ が区間内で返すフレーム特徴を

$$r_{i,t,m} \in \mathbb{R}^{d_0}, \quad m = 1, \dots, M_{i,t} \quad (4)$$

とする。ここで、 $M_{i,t}$ は第 t 区間内の MuQ フレーム数、 d_0 は MuQ 表現の次元である。各 5 秒区間を一つの音楽的状态単位として扱うため、区間内平均

$$z_i^{(t)} = \frac{1}{M_{i,t}} \sum_{m=1}^{M_{i,t}} r_{i,t,m} \in \mathbb{R}^{d_0} \quad (5)$$

を用いる。これにより、楽曲 i は区間特徴列

$$Z_i = (z_i^{(1)}, z_i^{(2)}, \dots, z_i^{(T_i)}) \in \mathbb{R}^{T_i \times d_0} \quad (6)$$

として表現される。

2.3 Transformer による文脈付き表現

MuQ で得られる $z_i^{(t)}$ は各 5 秒区間の局所的特徴である。しかし、楽曲構造を理解するためには、ある区間が前後の展開や過去の再訪とどのような関係を持つかを考慮する必要がある。そこで本研究では、TCN ではなく Transformer encoder を用いて、区間特徴列に対する文脈付き表現を構成する。

まず、入力特徴を Transformer の内部次元 d へ射影する。

$$e_i^{(t)} = W_{\text{in}} z_i^{(t)} + b_{\text{in}} \in \mathbb{R}^d \quad (7)$$

さらに、時系列順序を保持するため、位置埋め込み $p^{(t)} \in \mathbb{R}^d$ を加え、

$$u_i^{(t)} = e_i^{(t)} + p^{(t)} \quad (8)$$

とする。Transformer encoder を F_{θ}^{Tr} と書くと、文脈付き表現列は

$$H_i = F_{\theta}^{\text{Tr}}(u_i^{(1)}, \dots, u_i^{(T_i)}) = (h_i^{(1)}, \dots, h_i^{(T_i)}) \quad (9)$$

で与えられる。ここで $h_i^{(t)} \in \mathbb{R}^d$ である。Transformer

の自己注意機構は、入力行列 $U_i = (u_i^{(1)}, \dots, u_i^{(T_i)})$ に対して、

$$Q = U_i W_Q, \quad K = U_i W_K, \quad V = U_i W_V \quad (10)$$

を計算し、

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right)V \quad (11)$$

により時点間関係を集約する。このため、 $h_i^{(t)}$ は区間 t 単独の特徴ではなく、楽曲内の他区間との関係を反映した文脈付き表現となる。したがって、隣接区間の変化だけでなく、離れた区間同士の反復、再訪、対比を後段の確率経路へ反映できる。

2.4 (P²OT) による確率単体上への状態表現化

次に、Transformer で得られた文脈付き表現 $h_i^{(t)}$ を、 K 個の潜在音楽状態への帰属確率へ写像する。潜在状態プロトタイプを

$$c_1, c_2, \dots, c_K \in \mathbb{R}^d \quad (12)$$

とする。各時刻 t とプロトタイプ k の類似度を、例えば cosine 類似度により

$$a_{i,t,k} = \text{sim}(h_i^{(t)}, c_k) = \frac{\langle h_i^{(t)}, c_k \rangle}{\|h_i^{(t)}\| \|c_k\|} \quad (13)$$

と定義する。温度パラメータ $\tau > 0$ を用いると、予測確率は

$$p_{i,t,k} = \frac{\exp(a_{i,t,k}/\tau)}{\sum_{\ell=1}^K \exp(a_{i,t,\ell}/\tau)} \quad (14)$$

である。したがって、

$$p_i^{(t)} = (p_{i,t,1}, \dots, p_{i,t,K}) \in \Delta^{K-1} \quad (15)$$

であり、確率単体は

$$\Delta^{K-1} = \left\{ p \in \mathbb{R}^K \mid p_k \geq 0, \sum_{k=1}^K p_k = 1 \right\} \quad (16)$$

で定義される。

本研究では、単純な hard assignment ではなく、(P²OT) に基づく pseudo-label 生成を導入する。音楽では、サビ、導入、間奏、ブレイクなどの状態が均等に出現するとは限らず、また境界付近には曖昧な区間が存在する。そのため、均等クラスタを強く仮定するのではなく、不均衡を許容しながら高信頼な区間から段階的に学習することが重要である。

ミニバッチ内の N 個の 5 秒区間を $n = 1, \dots, N$ と書

き直し、予測行列を

$$P = [p_{n,k}] \in \mathbb{R}_+^{N \times K} \quad (17)$$

とする。(P²OT) では、pseudo-label 行列 $Q = [q_{n,k}]$ を以下の最適化問題として求める。なお、本章では後述の Gromov–Wasserstein 型構造距離で用いる輸送計画 ρ と区別するため、(P²OT) の選択質量を ϱ と書く。

$$Q^* = \operatorname{argmin}_{Q \in \Pi_\varrho} \left\{ \langle Q, -\log P \rangle_F + \lambda \operatorname{KL} \left(Q^\top \mathbf{1}_N, \frac{\varrho}{K} \mathbf{1}_K \right) \right\}. \quad (18)$$

制約集合は

$$\Pi_\varrho = \left\{ Q \in \mathbb{R}_+^{N \times K} \mid Q \mathbf{1}_K \leq \frac{1}{N} \mathbf{1}_N, \mathbf{1}_N^\top Q \mathbf{1}_K = \varrho \right\} \quad (19)$$

である。第一項はモデル予測 P と pseudo-label Q の整合性を表し、第二項は全サンプルが一つの状態へ潰れることを防ぐためのクラスタ分布制御である。また、 ϱ は実クラスタに割り当てる総質量であり、学習初期では小さく、学習が進むにつれて大きくする。例えば、学習ステップ s 、総ステップ数 S に対し、

$$\varrho(s) = \varrho_0 + (\varrho_{\max} - \varrho_0) \exp \left[-5 \left(1 - \frac{s}{S} \right)^2 \right] \quad (20)$$

とする。これにより、初期には明確な区間を中心に学習し、後半では曖昧な遷移区間も取り込むことができる。

(P²OT) により得られる Q^* は学習時の pseudo-label として用いる。モデル予測 P を Q^* に近づける損失を

$$\mathcal{L}_{\text{P}^2\text{OT}} = - \sum_{n=1}^N \sum_{k=1}^K q_{n,k}^* \log p_{n,k} \quad (21)$$

とする。また、必要に応じて時系列的な過度な振動を抑えるため、

$$\mathcal{L}_{\text{smooth}} = \sum_i \sum_{t=1}^{T_i-1} D_{\text{JS}} \left(p_i^{(t)}, p_i^{(t+1)} \right) \quad (22)$$

を加え、

$$\mathcal{L} = \mathcal{L}_{\text{P}^2\text{OT}} + \lambda_{\text{smooth}} \mathcal{L}_{\text{smooth}} \quad (23)$$

を最小化する。ただし、 λ_{smooth} を大きくしすぎるとサビ入りやドロップなどの急激な変化を潰す可能性があるため、検証データに基づいて調整する。

学習後には、ミニバッチ依存の Q^* ではなく、Transformer とプロトタイプから得られる予測確率を用いる。すなわち、

$$\gamma_i^{(t)} := p_i^{(t)} \in \Delta^{K-1} \quad (24)$$

を時刻 t における特徴確率ベクトルとする。これは、高次元の文脈付き特徴を、 K 次元の確率単体上の潜在状態確率へ圧縮した表現である。したがって、(P²OT) は PCA のような線形次元削減ではなく、不均衡を許容した深層クラスタリングにより、音楽の状態を確率的に表現する役割を持つ。

2.5 特徴確率経路と自己距離行列

各楽曲に対して得られる確率ベクトル列

$$\Gamma_i = \left(\gamma_i^{(1)}, \gamma_i^{(2)}, \dots, \gamma_i^{(T_i)} \right) \quad (25)$$

を、本研究では特徴確率経路と呼ぶ。これは、楽曲 i の音楽的状态が時間とともにどのように遷移するかを、確率単体上の経路として表したものである。

確率ベクトル $p, q \in \Delta^{K-1}$ に対して、Jensen–Shannon divergence を

$$D_{\text{JS}}(p, q) = \frac{1}{2} D_{\text{KL}}(p \| m) + \frac{1}{2} D_{\text{KL}}(q \| m), \quad m = \frac{p+q}{2} \quad (26)$$

で定義する。ここで

$$D_{\text{KL}}(p \| m) = \sum_{k=1}^K p_k \log \frac{p_k}{m_k} \quad (27)$$

である。本研究では局所距離として

$$d_{\sqrt{\text{JS}}}(p, q) = \sqrt{D_{\text{JS}}(p, q)} \quad (28)$$

を用いる。自然対数を用いる場合、

$$0 \leq d_{\sqrt{\text{JS}}}(p, q) \leq \sqrt{\log 2} \quad (29)$$

である。

楽曲 i の全時刻間の距離を並べた自己距離行列を

$$\mathcal{A}_i(t, s) = \sqrt{D_{\text{JS}} \left(\gamma_i^{(t)}, \gamma_i^{(s)} \right)}, \quad t, s = 1, \dots, T_i \quad (30)$$

と定義する。行列表示では

$$\mathcal{A}_i = [\mathcal{A}_i(t, s)]_{t,s=1}^{T_i} \in \mathbb{R}^{T_i \times T_i} \quad (31)$$

である。 $\mathcal{A}_i$ は対称行列であり、対角成分は 0 である。この行列により、隣接時刻の局所変化だけでなく、離れた時刻間の反復、再訪、対比、内部構造を同一表現から考察できる。例えば、局所変化量は

$$\delta_i^{(t)} = \mathcal{A}_i(t, t-1), \quad t = 2, \dots, T_i \quad (32)$$

として取り出せる。また、最小時間間隔 $L_{\min}$ を用いる

と、状態再訪スコアは

$$d_{\text{revisit},i}^{(t)} = \min_{1 \leq s \leq t-L_{\min}} \mathcal{A}_i(t, s) \quad (33)$$

として定義できる。この値が小さいほど、時刻 t の状態が過去のいずれかの状態に近いことを表す。

2.6 平均・経路・構造による三項比較

楽曲間比較では、平均的特徴、時間的展開、内部自己構造の三側面を統合する。まず、楽曲 i の平均確率状態を

$$\bar{\gamma}_i = \frac{1}{T_i} \sum_{t=1}^{T_i} \gamma_i^{(t)} \quad (34)$$

とし、平均項を

$$D_{\text{mean}}(i, j) = \sqrt{D_{\text{JS}}(\bar{\gamma}_i, \bar{\gamma}_j)} \quad (35)$$

で定義する。これは、曲全体としてどの潜在状態に滞在しやすいかを比較する項である。

次に、特徴確率経路 Γ_i, Γ_j の時間的展開を比較するため DTW を用いる。DTW の許容経路を

$$\pi = ((t_1, s_1), \dots, (t_L, s_L)) \in \Pi_{\text{DTW}}(T_i, T_j) \quad (36)$$

とし、経路コストを

$$C(\pi; \Gamma_i, \Gamma_j) = \sum_{m=1}^L \sqrt{D_{\text{JS}}(\gamma_i^{(t_m)}, \gamma_j^{(s_m)})} \quad (37)$$

と定義する。最適経路を

$$\pi_{i,j}^* \in \underset{\pi \in \Pi_{\text{DTW}}(T_i, T_j)}{\operatorname{argmin}} C(\pi; \Gamma_i, \Gamma_j) \quad (38)$$

とし、正規化経路距離を

$$D_{\text{path}}(i, j) = \frac{C(\pi_{i,j}^*; \Gamma_i, \Gamma_j)}{|\pi_{i,j}^*|} \quad (39)$$

で定義する。これは、楽曲間の状態遷移の流れがどの程度似ているかを表す。

さらに、内部構造の類似性を比較するため、自己距離行列に基づく Gromov-Wasserstein 型の構造項を導入する。楽曲 i, j の自己距離行列を $\mathcal{A}_i, \mathcal{A}_j$ とし、各時刻上の一様分布を

$$p_i(t) = \frac{1}{T_i}, \quad p_j(u) = \frac{1}{T_j} \quad (40)$$

とする。輸送計画集合を

$$\Pi(p_i, p_j) = \left\{ \rho \in \mathbb{R}_+^{T_i \times T_j} \mid \rho \mathbf{1} = p_i, \rho^\top \mathbf{1} = p_j \right\} \quad (41)$$

と定義する。さらに、

$$L_{t,s,u,v} = |\mathcal{A}_i(t, s) - \mathcal{A}_j(u, v)|^2 \quad (42)$$

とおく。このとき構造距離を

$$D_{\text{struct}}(i, j) = \left[\min_{\rho \in \Pi(p_i, p_j)} \sum_{t,s,u,v} L_{t,s,u,v} \rho_{t,u} \rho_{s,v} \right]^{1/2} \quad (43)$$

で定義する。これは、二つの楽曲の内部距離構造が、柔軟に対応 ρ のもとでどの程度類似しているかを測る項である。

以上を統合し、総合距離を

$$D_{\eta,\alpha,\beta}(i, j) = \eta D_{\text{mean}}(i, j) + \alpha D_{\text{path}}(i, j) + \beta D_{\text{struct}}(i, j) \quad (44)$$

と定義する。ただし、

$$\eta + \alpha + \beta = 1, \quad \eta, \alpha, \beta \geq 0 \quad (45)$$

である。また、各項は比較可能なスケールに揃えるため、実装上は必要に応じて $\sqrt{\log 2}$ など正規化した値を用いる。平均項は静的状態、経路項は時間的展開、構造項は反復・再訪・対比を含む内部構造を表す。したがって、三項評価は、楽曲を時間的に展開する確率的構造体として比較するための総合距離である。

2.7 アルゴリズム形式

最後に、本研究で用いる処理をアルゴリズム形式で整理する。

Algorithm 1: MuQ + Transformer + (P²OT) による特徴確率経路生成と三項評価

- Step 1.** 各楽曲 x_i を 5 秒区間 $x_i^{(1)}, \dots, x_i^{(T_i)}$ に分割する。末尾区間は 5 秒未満でも一つの区間として扱う。
- Step 2.** 各区間 $x_i^{(t)}$ を MuQ に入力し、フレーム特徴 $r_{i,t,m} \in \mathbb{R}^{d_0}$ を得る。
- Step 3.** 各区間内で平均を取り、5 秒平均特徴 $z_i^{(t)} = M_{i,t}^{-1} \sum_m r_{i,t,m}$ を得る。
- Step 4.** 楽曲ごとの特徴列 $Z_i = (z_i^{(1)}, \dots, z_i^{(T_i)})$ を Transformer encoder に入力し、文脈付き表現 $h_i^{(t)}$ を得る。
- Step 5.** K 個の学習可能なプロトタイプ $c_1, \dots, c_K$ を用意し、類似度 $a_{i,t,k} = \text{sim}(h_i^{(t)}, c_k)$ を計算する。
- Step 6.** softmax により予測確率 $p_i^{(t)} \in \Delta^{K-1}$ を得る。
- Step 7.** 学習時には、ミニバッチ上の予測行列 P から (P²OT) により pseudo-label Q^* を生成する。
- Step 8.** 損失 $\mathcal{L}_{\text{P}^2\text{OT}}$ と必要に応じた平滑化損失 $\mathcal{L}_{\text{smooth}}$ に

より, Transformer とプロトタイプを更新する.

Step 9. 学習後は, $\gamma_i^{(t)} := p_i^{(t)}$ として, 各時刻を確率単体上の特徴確率ベクトルとして表す.

Step 10. 特徴確率経路 $\Gamma_i = (\gamma_i^{(1)}, \dots, \gamma_i^{(T_i)})$ を構成する.

Step 11. 自己距離行列 $\mathcal{A}_i(t, s) = \sqrt{D_{JS}(\gamma_i^{(t)}, \gamma_i^{(s)})}$ を構成する.

Step 12. 平均項 D_{mean} , 経路項 D_{path} , 構造項 D_{struct} を計算する.

Step 13. 三項評価 $D_{\eta, \alpha, \beta}(i, j)$ により, 楽曲間の静的状態, 時間的展開, 内部構造を統合的に比較する.

Algorithm 2: (P²OT) pseudo-label 生成の計算手順

Step 1. 入力として予測確率行列 $P \in \mathbb{R}_+^{N \times K}$, 選択質量 ϱ , 正則化係数 ε , KL 重み λ を与える.

Step 2. 拡張コスト行列 $\hat{C} = [-\log P, 0_N] \in \mathbb{R}^{N \times (K+1)}$ を作る.

Step 3. 仮想クラスタを含む列側質量 $\beta = [(\varrho/K)\mathbf{1}_K^\top, 1 - \varrho]^\top$ を作る.

Step 4. 行側質量を $\alpha = N^{-1}\mathbf{1}_N$ とし, $M = \exp(-\hat{C}/\varepsilon)$ を計算する.

Step 5. $b \in \mathbb{R}_+^{K+1}$ を正のベクトルで初期化する.

Step 6. 収束まで, 次のスケール更新を反復する.

$$a \leftarrow \alpha/(Mb), \quad b \leftarrow (\beta/(M^\top a))^{\circ f} \quad (46)$$

ここで $f = \lambda/(\lambda + \varepsilon)$ であり, 累乗および割り算は成分ごとに行う.

Step 7. 収束後, $\hat{Q}^* = \text{diag}(a)M\text{diag}(b)$ を計算する.

Step 8. 仮想クラスタ列を除いた

$$Q^* = \hat{Q}_{:,1:K}^* \quad (47)$$

を pseudo-label として返す.

計算コストを考慮した実験上の近似

本研究では, 三項評価のうち経路項と構造項の計算コストが大きくなるため, 実験では近似的かつ実装可能な計算手順を採用する. まず, 経路項 $D_{\text{path}}(i, j)$ については, 厳密な DTW をすべての楽曲ペアに対して計算すると, 系列長 T_i, T_j に対しておおよそ $O(T_i T_j)$ の計算量を要する. したがって, 大規模な候補集合に対する実験では, 近似 DTW 手法である FastDTW を用い [17], 局所

コストには従来通り

$$d_{\sqrt{JS}}(\gamma_i^{(t)}, \gamma_j^{(s)}) = \sqrt{D_{JS}(\gamma_i^{(t)}, \gamma_j^{(s)})} \quad (48)$$

を用いる. FastDTW は厳密 DTW の近似であるため, 最終的な評価では, 候補数を絞った後に厳密 DTW との比較も行い, 近似による誤差が実験結果に与える影響を確認する.

次に, 構造項 $D_{\text{struct}}(i, j)$ については, 自己距離行列 $\mathcal{A}_i, \mathcal{A}_j$ の全ペア関係を比較するため, 通常の Gromov–Wasserstein 型最適化は計算量が多い. そこで実験では, エントロピー正則化を加えた entropic Gromov–Wasserstein 距離を用いる [19, 18]. 正則化係数を $\varepsilon_{\text{GW}} > 0$ とし, $\rho \in \Pi(p_i, p_j)$ に対して

$$D_{\text{EGW}}^2(i, j) = \min_{\rho \in \Pi(p_i, p_j)} \sum_{t, s, u, v} |\mathcal{A}_i(t, s) - \mathcal{A}_j(u, v)|^2 \rho_{t, u} \rho_{s, v} - \varepsilon_{\text{GW}} H(\rho) \quad (49)$$

と定義する. ここで

$$H(\rho) = - \sum_{t, u} \rho_{t, u} \log \rho_{t, u} \quad (50)$$

は輸送計画のエントロピーである. エントロピー正則化により, 輸送計画の推定が数値的に安定し, Sinkhorn 型の反復計算により実装しやすくなる. 本研究の実験では, 三項評価の構造項として

$$\tilde{D}_{\text{struct}}(i, j) = \frac{D_{\text{EGW}}(i, j)}{\sqrt{\log 2}} \quad (51)$$

を用いる.

以上より, 実験段階では, 平均項で大まかな候補を絞り, FastDTW による経路項と entropic Gromov–Wasserstein 距離による構造項を用いて再評価する. これにより, 計算コストを抑えつつ, 楽曲の平均的状态, 時間的展開, 内部自己構造を統合した比較を実装する. ただし, これらはいずれも計算上の近似を含むため, 主要な実験では近似パラメータを変えた感度分析を行い, 提案手法の頑健性を確認する.

以上の手順により, 本研究では, 音響信号から抽出された時系列特徴を, 文脈付き表現, 確率単体上の状態確率, 特徴確率経路, 自己距離行列へと段階的に変換する. その結果, 楽曲を単一ラベルや単一ベクトルへ還元せず, 時間的展開と内部構造を保持した比較可能な表現基盤として扱うことが可能となる.

References

- [1] H. Datta, G. Knox, and B. J. Bronnenberg, “Changing Their Tune: How Consumers’ Adoption of Online Streaming Affects Music Consumption and Discovery,” *Marketing Science*, vol. 37, no. 1, pp. 5–21, 2018.
- [2] M. Stassen, “Global audio streams jumped 14% in 2024 to 4.8 trillion, as Pop music was the fastest-growing genre in the US,” *Music Business Worldwide*, Jan. 21, 2025.
- [3] Spotify, “There are millions of artist profiles on Spotify, yet only a small fraction are generating money. Shouldn’t a higher percentage of all artists on Spotify be making money? Aren’t there 8 million artists on Spotify?,” *Loud & Clear FAQ*, accessed 2026.
- [4] M. Sordo, O. Celma, M. Blech, and E. Guaus, “The Quest for Musical Genres: Do the Experts and the Wisdom of Crowds Agree?,” *Proceedings of the 9th International Society for Music Information Retrieval Conference*, pp. 255–260, 2008.
- [5] D. Kowald, M. Schedl, and E. Lex, “The Unfairness of Popularity Bias in Music Recommendation: A Reproducibility Study,” *Advances in Information Retrieval, ECIR 2020*, pp. 35–42, 2020.
- [6] M. Mansoury, H. Abdollahpouri, M. Pechenizkiy, B. Mobasher, and R. Burke, “Feedback Loop and Bias Amplification in Recommender Systems,” *Proceedings of the 29th ACM International Conference on Information and Knowledge Management*, pp. 2145–2148, 2020.
- [7] O. Nieto, G. J. Mysore, C.-i. Wang, J. B. L. Smith, J. Schluter, T. Grill, and B. McFee, “Audio-Based Music Structure Analysis: Current Trends, Open Challenges, and Applications,” *Transactions of the International Society for Music Information Retrieval*, vol. 3, no. 1, pp. 246–263, 2020.
- [8] Music Information Retrieval Evaluation eXchange (MIREX), “2025: Music Structure Analysis,” *MIREX Wiki*, accessed 2026.
- [9] T. Kim and J. Nam, “All-In-One Metrical and Functional Structure Analysis with Neighborhood Attentions on Demixed Audio,” *IEEE Workshop on Applications of Signal Processing to Audio and Acoustics (WASPAA)*, 2023.
- [10] Y. Zhang, H. Chen, J.-C. Wang, and J. Chen, “Temporal Adaptation of Pre-trained Foundation Models for Music Structure Analysis,” *arXiv:2507.13572*, 2025.
- [11] K. Toyama, Z. Zhong, A. Takahashi, S. Takahashi, and Y. Mitsufuji, “Do Foundational Audio Encoders Understand Music Structure?,” *arXiv:2512.17209*, 2026.
- [12] H. Zhu, Y. Zhou, H. Chen, J. Yu, Z. Ma, R. Gu, Y. Luo, W. Tan, and X. Chen, “MuQ: Self-Supervised Music Representation Learning with Mel Residual Vector Quantization,” *arXiv:2501.01108*, 2025.
- [13] C. Zhang, H. Ren, and X. He, “P²OT: Progressive Partial Optimal Transport for Deep Imbalanced Clustering,” *International Conference on Learning Representations (ICLR)*, 2024.
- [14] M. Buisson, B. McFee, and S. Essid, “Using Pairwise Link Prediction and Graph Attention Networks for Music Structure Analysis,” *Proceedings of the 25th International Society for Music Information Retrieval Conference*, 2024.
- [15] T.-P. Chen and K. Yoshii, “Joint Music Segmentation and Clustering Based on Self-Attentive Contrastive Learning of Multifaceted Self-Similarity Representation,” *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 33, pp. 1267–1280, 2025.
- [16] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention Is All You Need,” *Advances in Neural Information Processing Systems*, 2017.
- [17] S. Salvador and P. Chan, “Toward Accurate Dynamic Time Warping in Linear Time and Space,” *Intelligent Data Analysis*, vol. 11, no. 5, pp. 561–580, 2007.
- [18] M. Cuturi, “Sinkhorn Distances: Lightspeed Computation of Optimal Transport,” *Advances in Neural Information Processing Systems*, 2013.
- [19] G. Peyré, M. Cuturi, and J. Solomon, “Gromov–Wasserstein Averaging of Kernel and Distance Matrices,” *Proceedings of the 33rd International Conference on Machine Learning*, pp. 2664–2672, 2016.
- [20] F. Memoli, “Gromov–Wasserstein Distances and the Metric Approach to Object Matching,” *Foundations of Computational Mathematics*, vol. 11, pp. 417–487, 2011.